FACULTAD DE INGENIERIA
Universidad de Buenos Aires

Introducción al Análisis Wavelet en Matlab

Ing. Fernando J. Chaure

Diapositivas, códigos y datos disponibles en: https://github.com/ferchaure/clase_wavelets



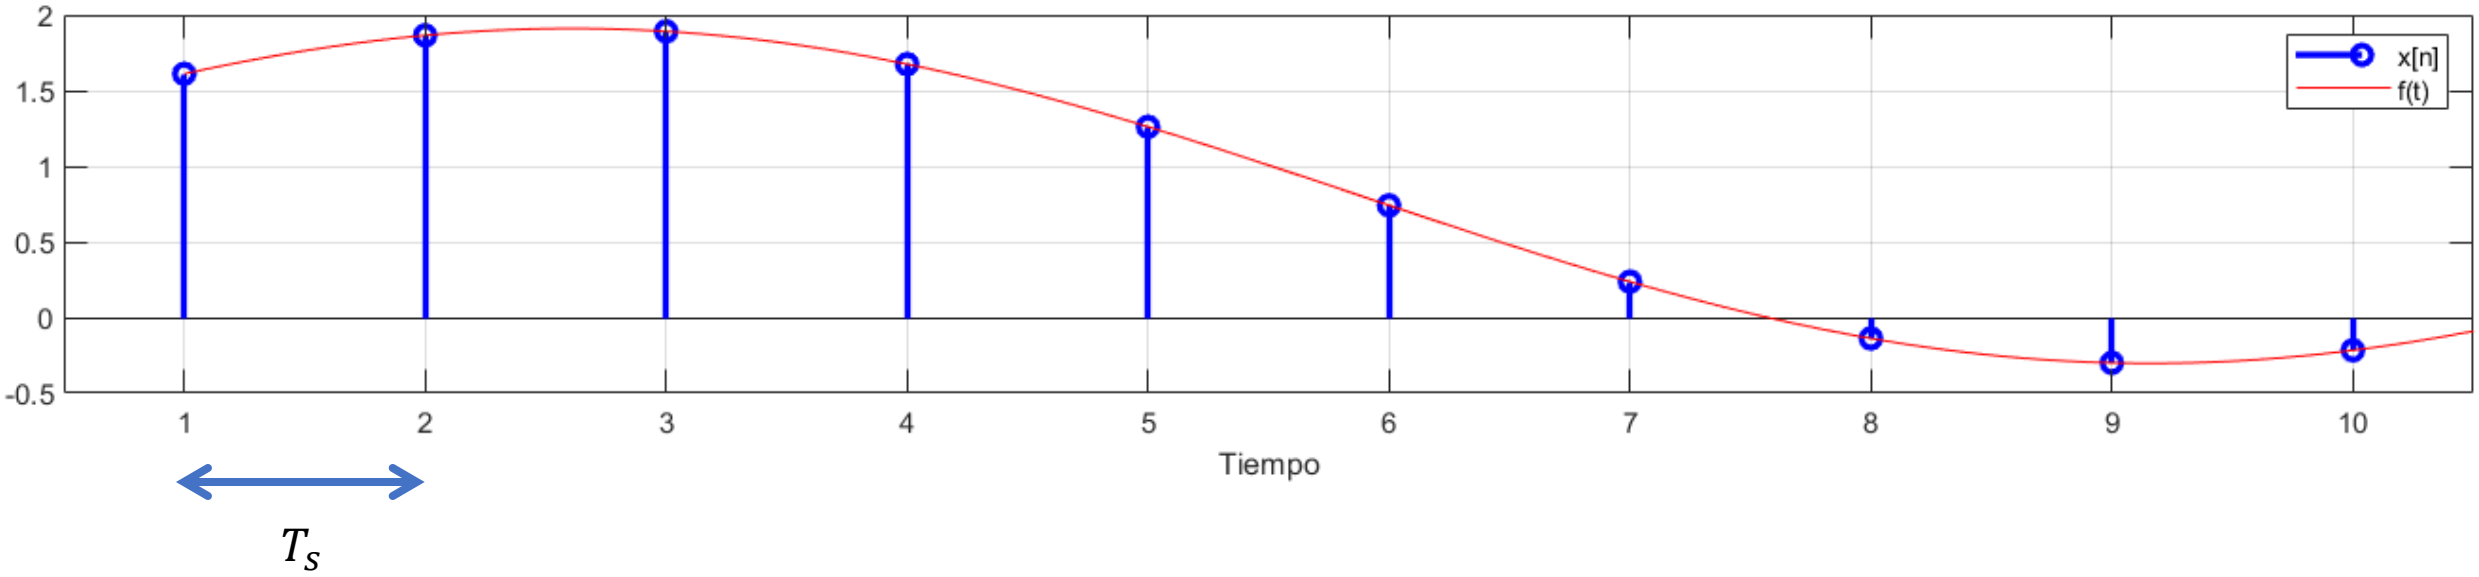
Introducción al Procesamiento de Señales en Tiempo Discreto

El código de los gráficos de esta sección están en intro_plots.m

Muestreo de Señales Continuas

Para analizar una función $f(t)$ se toman muestras cada cierto intervalo T_s obteniendo una función discreta:

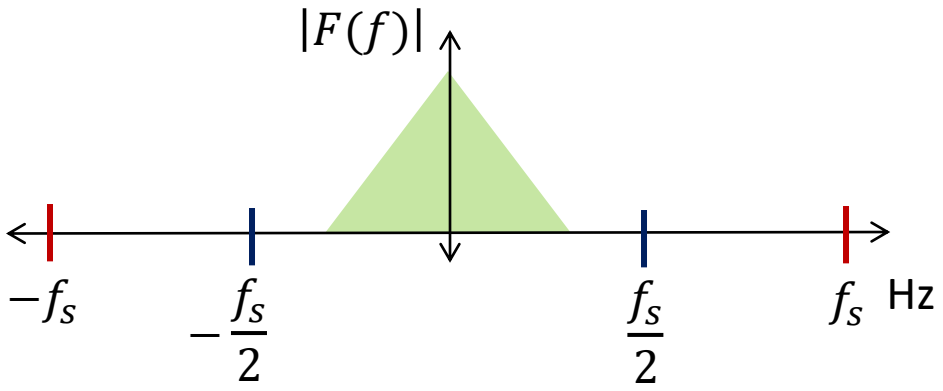
$$x[n] = f(T_s n) \qquad = f(\frac{n}{f_s})$$



Teorema de Muestreo de Nyquist–Shannon

Si el espectro de $f(t)$ esta contenido entre $\left(-\frac{f_s}{2}, \frac{f_s}{2}\right)$

$f(t)$ puede ser reconstruida a partir de $x[n]$.



El valor absoluto del espectro es simétrico para funciones reales

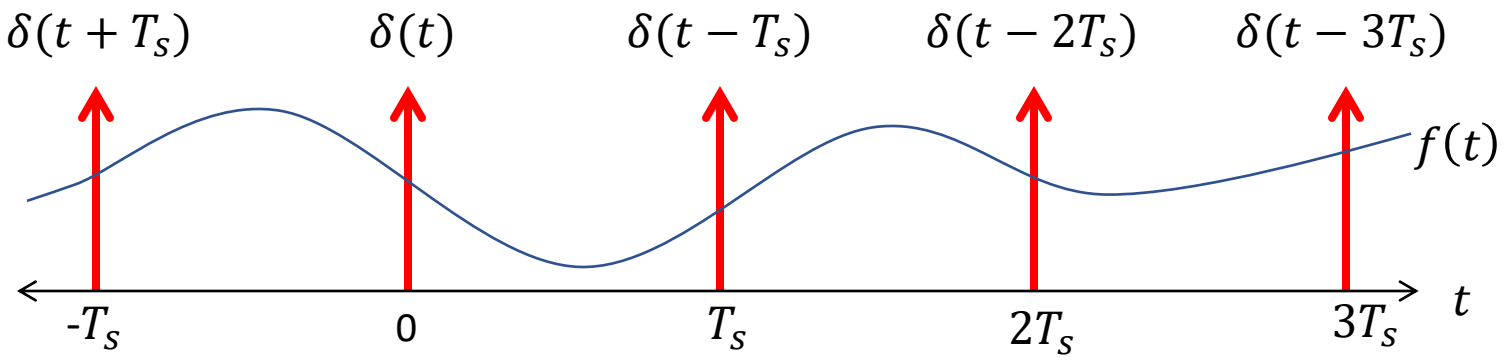
A la frecuencia $\frac{f_s}{2}$ se la conoce como *Frecuencia de Nyquist*

Enfoque Analítico del Muestreo (1)

Tener acceso solo a $x[n]$ implica que:

- Se dispone solo de los valores de la función en ciertos instantes de tiempo.
- Las operaciones con $\int dt$ solo pueden aplicarse como $\sum_n$

La forma analítica de manipular una $x[n]$ es considerarla el producto de $f(t)$ y un tren de deltas de Dirac de periodo T_s: $\sum_{n=-\infty}^{\infty} \delta(t - nT_s)$.



Delta de Dirac:

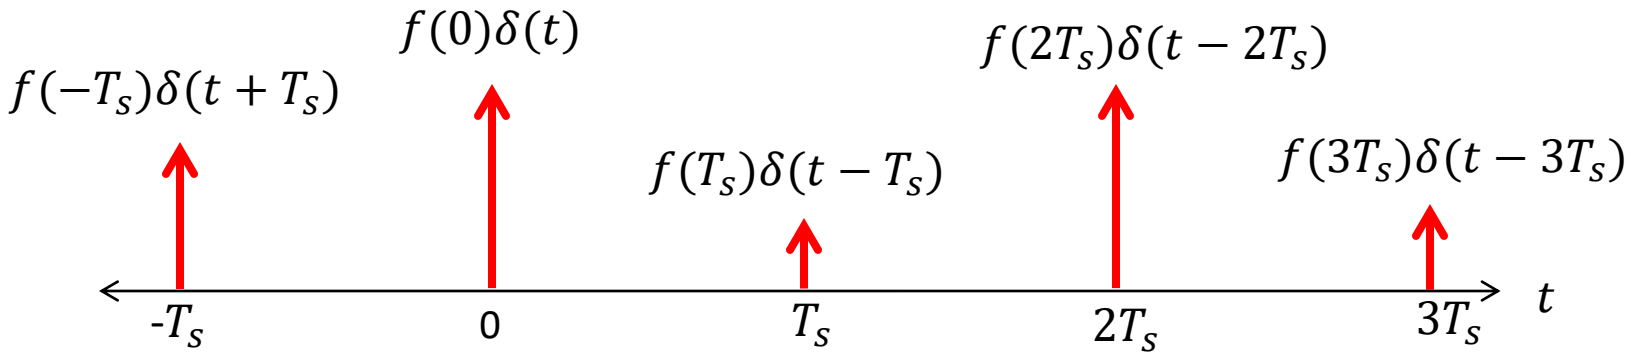
$$\int_{-\infty}^{\infty} \delta(x)\, dx = 1$$

$$\delta(x) = 0 \;\; sii \; x \neq 0$$

Enfoque Analítico del Muestreo (2)

Función “discretizada”:

$$\tilde{x}(t) = \sum_{n=-\infty}^{\infty} \delta(t - nT_s)\, f(t)$$



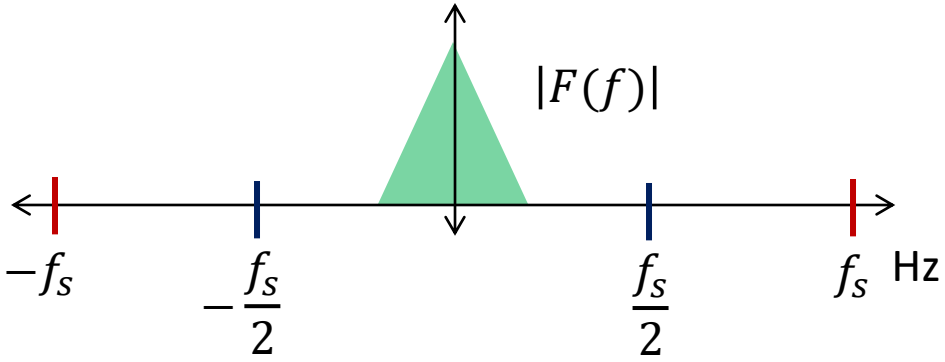
Ejemplo Integral:

$$\int_{-\infty}^{\infty} \tilde{x}(t)\, dt = \int_{-\infty}^{\infty} \sum_{n=-\infty}^{\infty} \delta(t - nT_s)\, f(t)\, dt = \sum_{n=-\infty}^{\infty} \int_{-\infty}^{\infty} \delta(t - nT_s) f(nT_s)\, dt = \sum_{n=-\infty}^{\infty} f(nT_s) \int_{-\infty}^{\infty} \delta(t - nT_s) dt = \sum_{n=-\infty}^{\infty} f(nT_s)$$

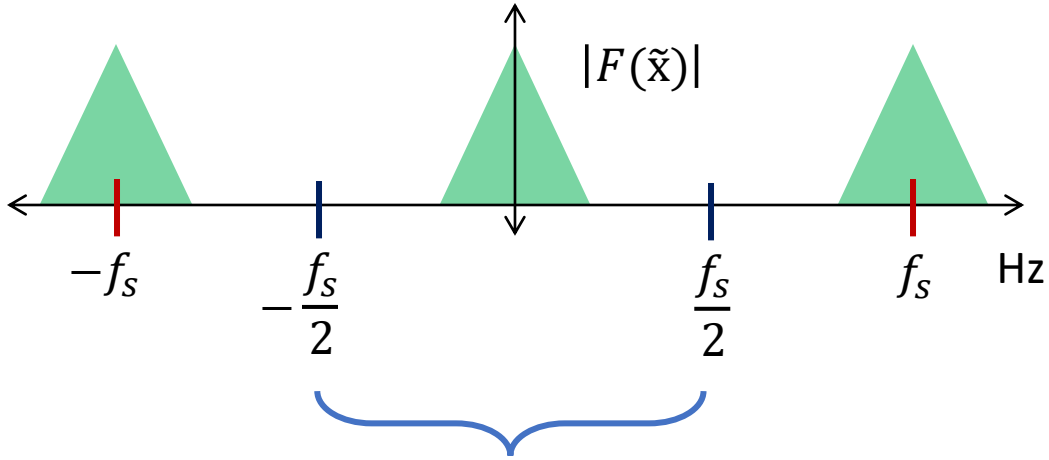
Luego del muestreo todo análisis integral queda reducido a operaciones de sumatorias.

Teorema de Muestreo: Espectro (1)

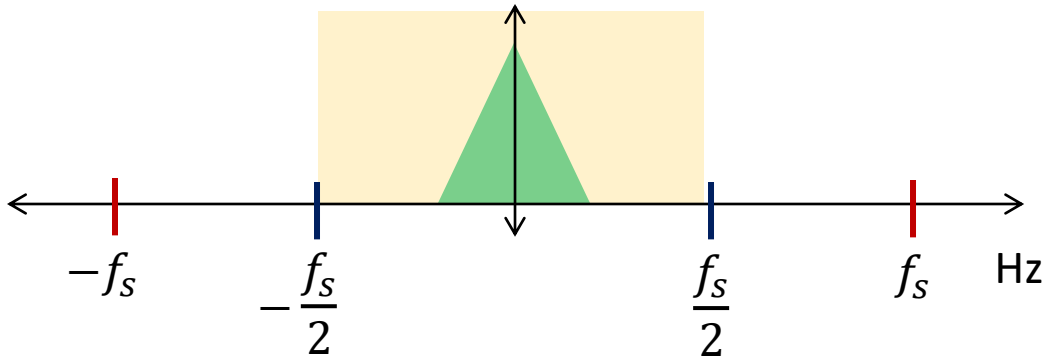
Como la transformada de Fourier de un tren de deltas de periodo T_s es un tren de deltas de periodo f_s. $F(\mathrm{x})$ es la convolución entre $F(\mathrm{f})$ y un tren de deltas. Gráficamente es hacer copias del espectro cada f_s. Resulta un espectro periódico de periodo f_s.



Muestreo



Filtro de Reconstrucción



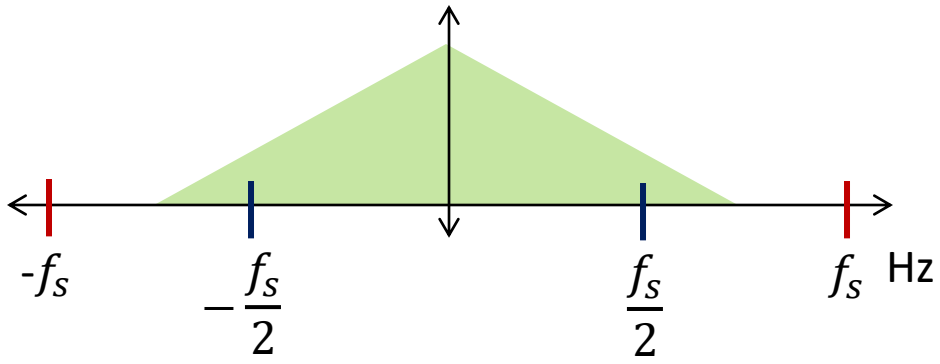
Reconstrucción

Aplicando un pasabajos

Si se cumplen las condiciones del Teorema del Muestreo, en este segmento se encuentra el espectro original

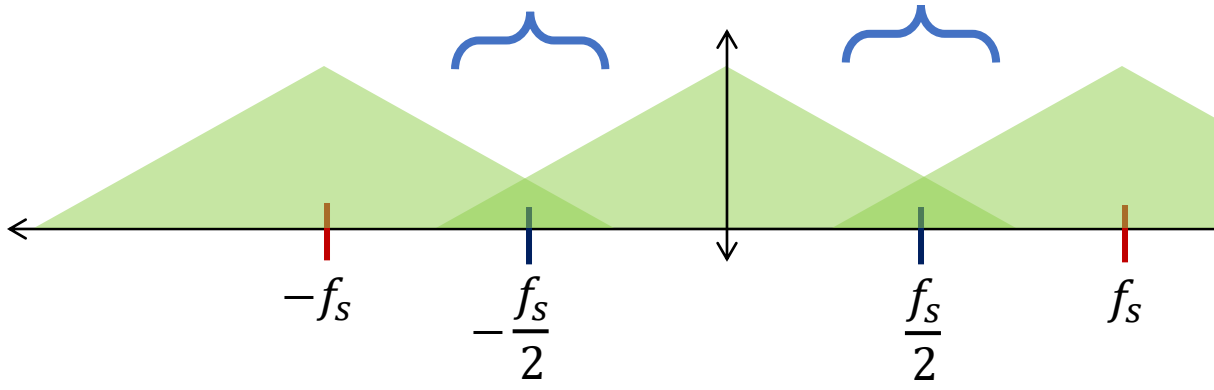
Teorema de Muestreo: Espectro (2)

Si espectro de la señal no cumple las condiciones del Teorema del Muestreo:

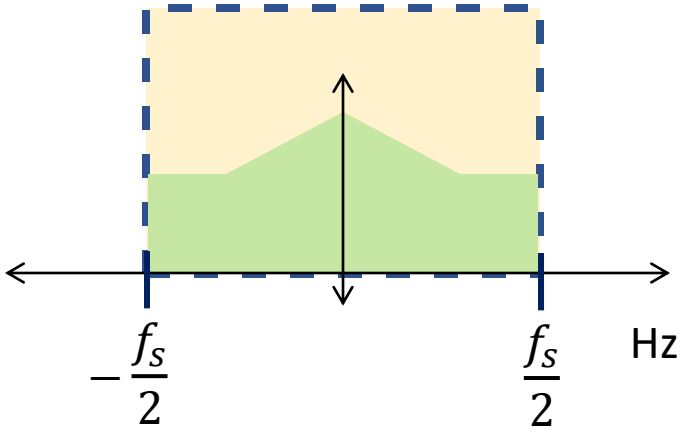


Muestreo

Superposiciones del espectro

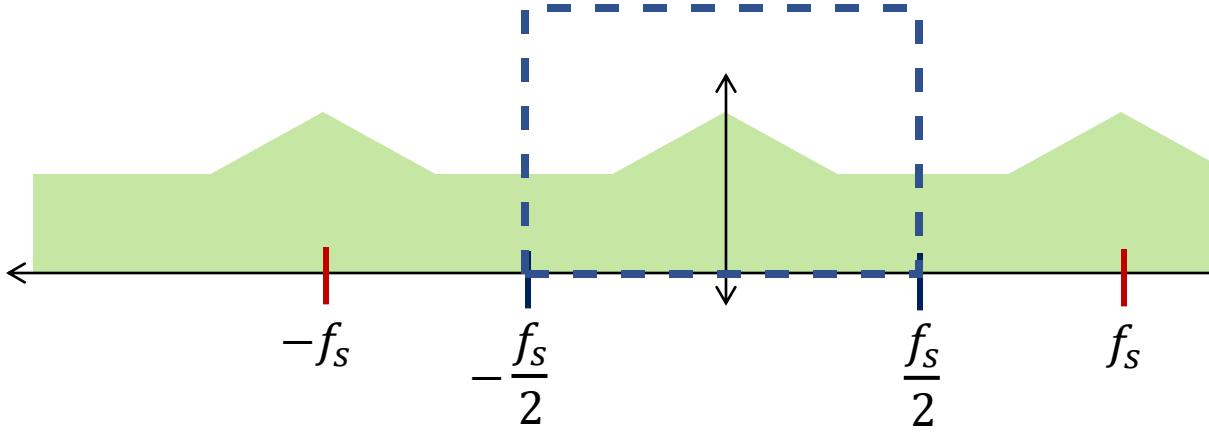


Filtro de Reconstrucción



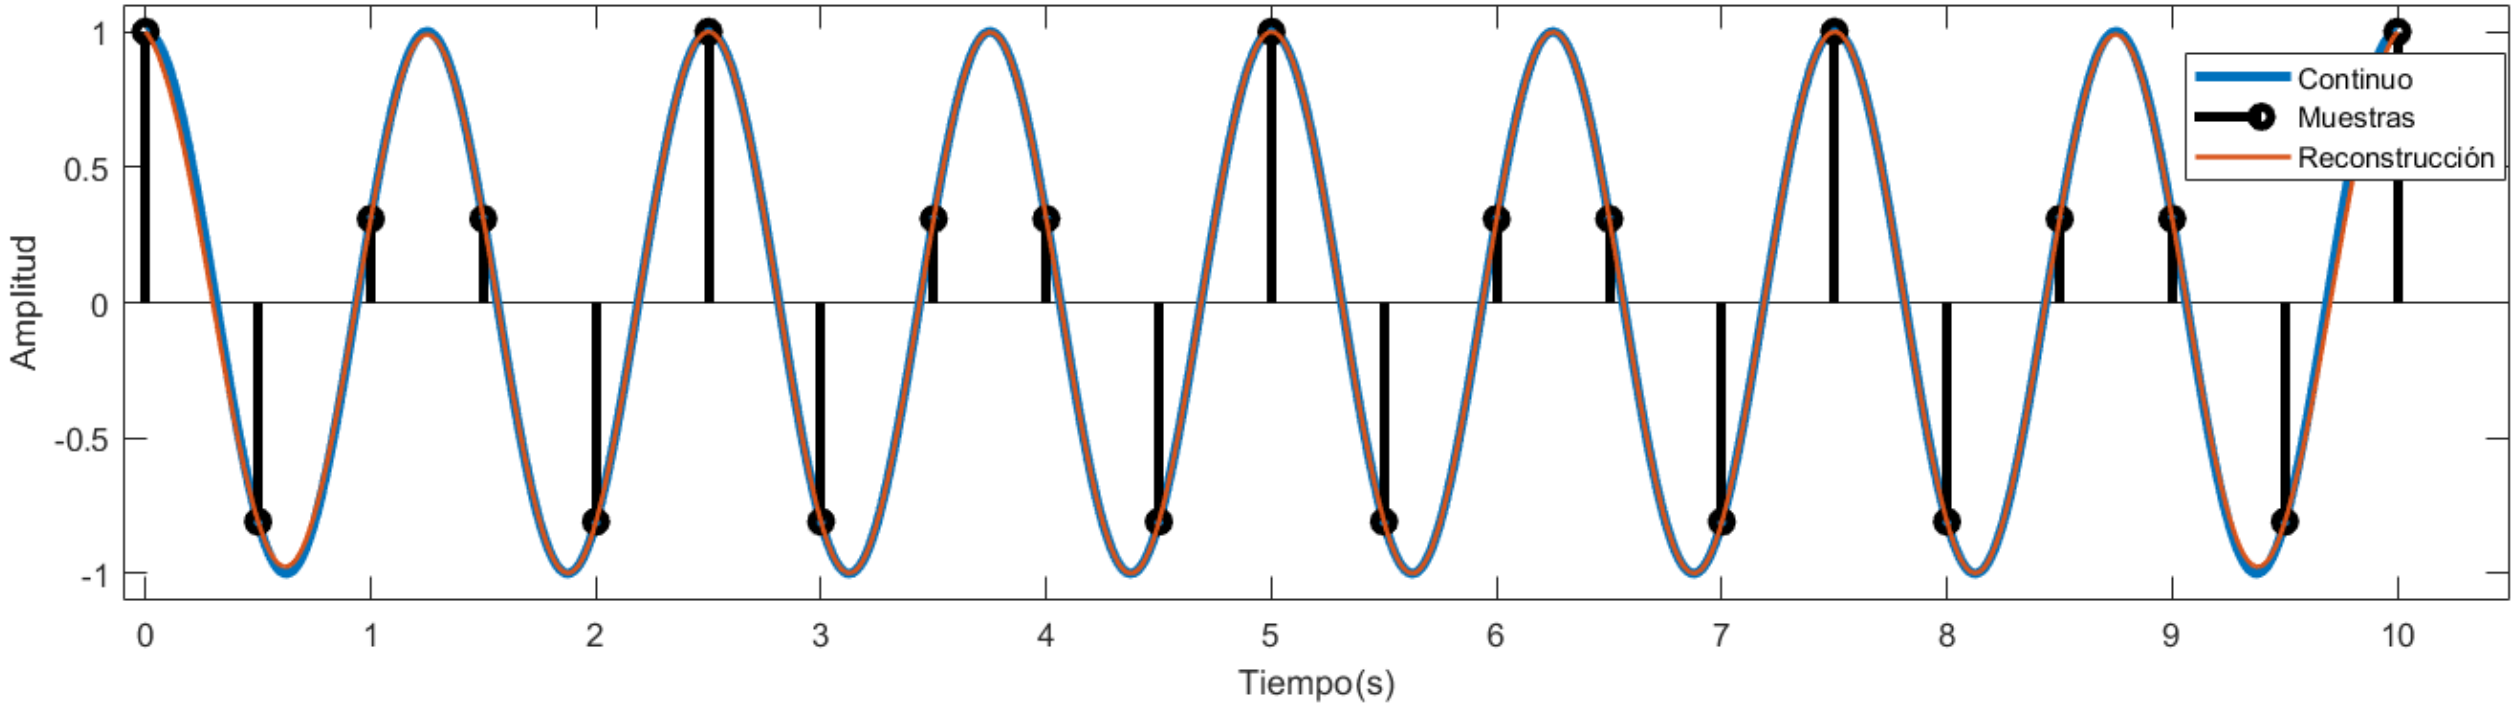
Reconstrucción

No es posible reconstruir la señal original



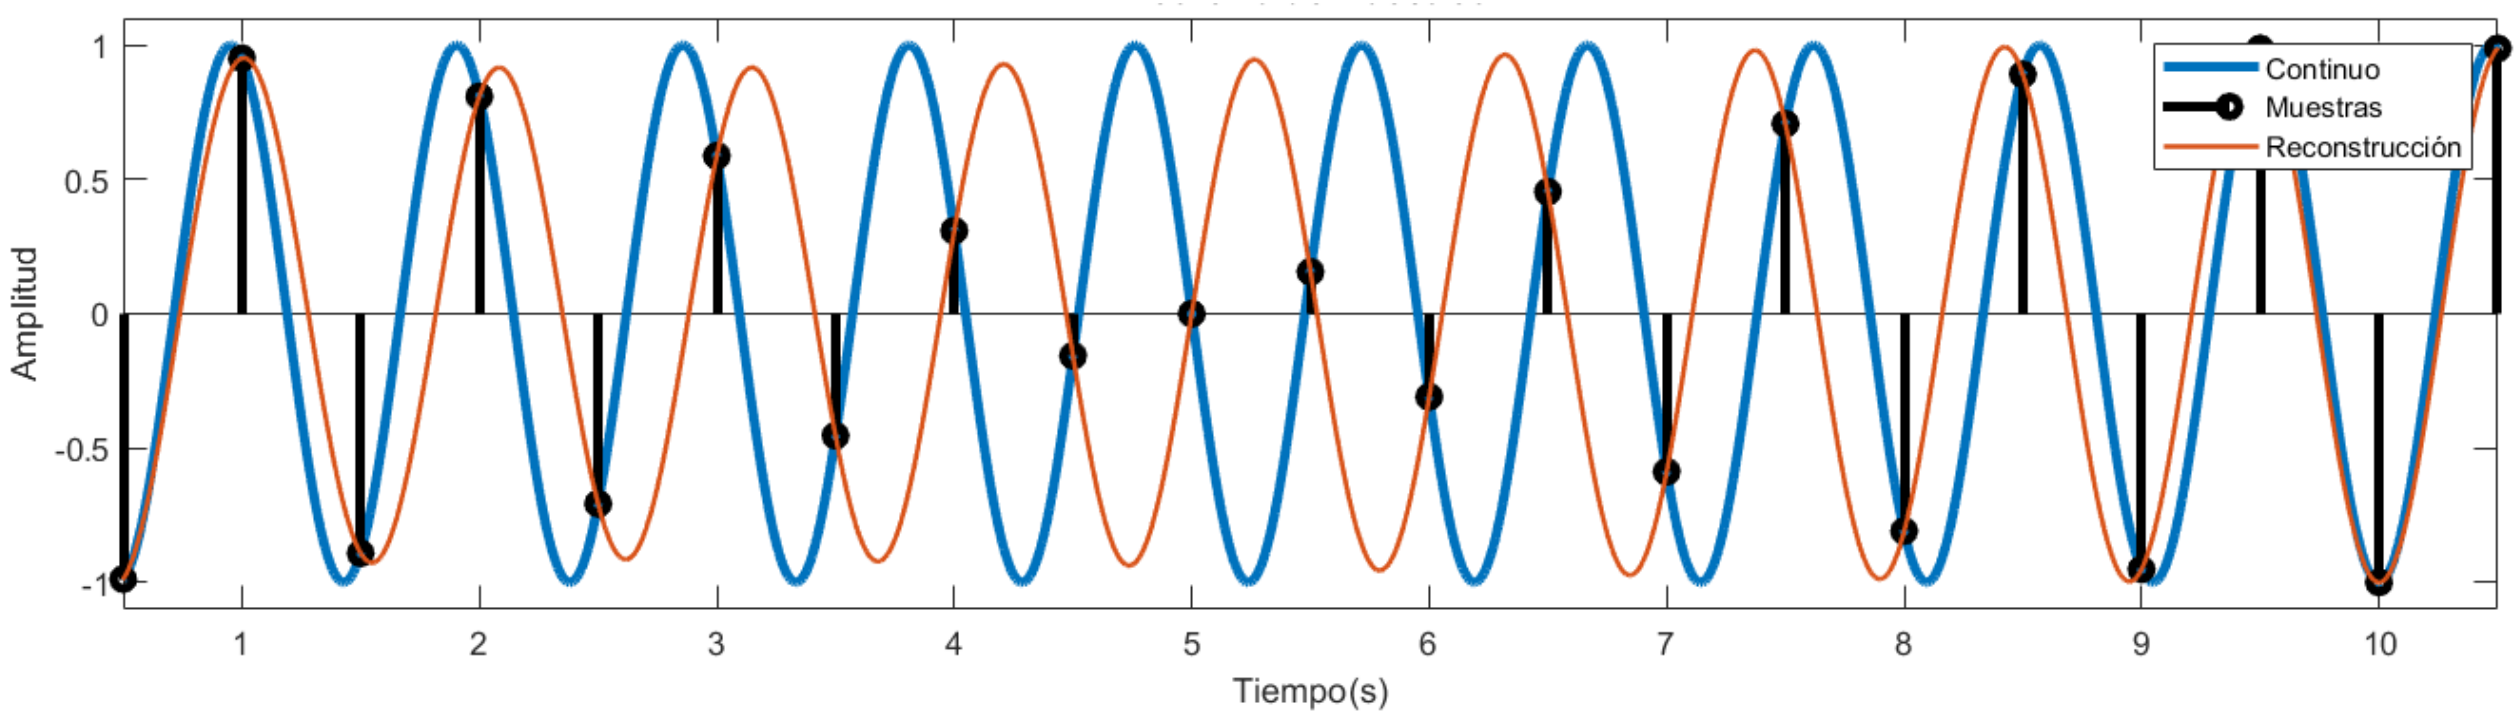
Teorema de Muestreo: Tiempo (1)

- $f_s = 2\ \mathrm{Hz}$ => $f_{nyq} = 1\ \mathrm{Hz}$
- $f(t) = \cos(2\pi\ 0.8\ t)$ => Espectro con componentes solo en $\pm 0.8\ Hz$
- Como $0.8 < 1$ => la señal puede reconstruirse



Teorema de Muestreo: Tiempo (2)

- $f_s = 2\ \mathrm{Hz}$ => $f_{nyq} = 1\ \mathrm{Hz}$
- $f(t) = \cos(2\pi\ 1.05\ t)$ => Espectro con componentes solo en $\pm 1.05\ Hz$
- Como $1.05 > 1$ => la señal **no** puede reconstruirse

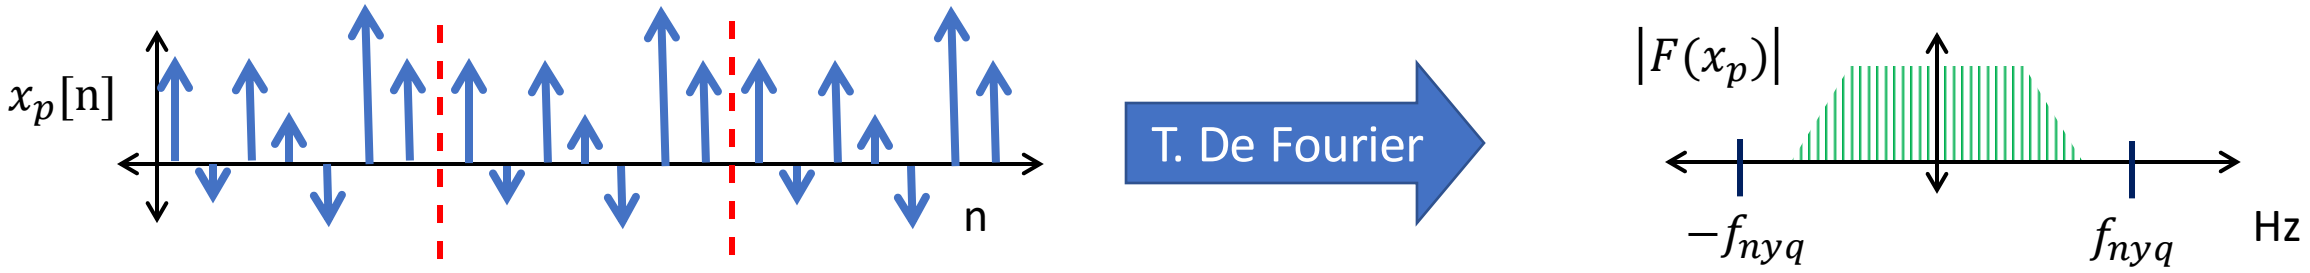


Espectros Digitalizados

- La teoría habla de señales digitales de infinitos elementos cuyo espectro esta sobre un continuo de frecuencias. Ninguno de estos dos elementos puede ser manipulado por una computadora de memoria finita.



- La solución es considerar que los N valores medidos, son los N elementos que componen un periodo de una función $\tilde{x}[n]$ periodica.



- Como en el caso continuo, los coeficientes de la Serie de Fourier definen todo el espectro.

Serie de Fourier de Tiempo Discreto (1)

- Para funciones discretas y periódicas, los coeficientes de la serie de Fourier se calculan como:

$$a_k = \frac{1}{N} \sum_{n=0}^{n=N-1} x[n]\, e^{-jn\frac{2\pi k}{N}}$$

- La antitransformada está dada por:

$$x[n] = \sum_{k=0}^{k=N-1} a_k\, e^{jk\frac{2\pi n}{N}}$$

Serie de Fourier de Tiempo Discreto (2)

- Notar que, dado que n es entero se cumple:

$$e^{-jn\frac{2\pi k}{N}} = e^{-j(n\frac{2\pi k}{N}+2\pi n)} = e^{-jn\frac{2\pi}{N}(k+N)}$$

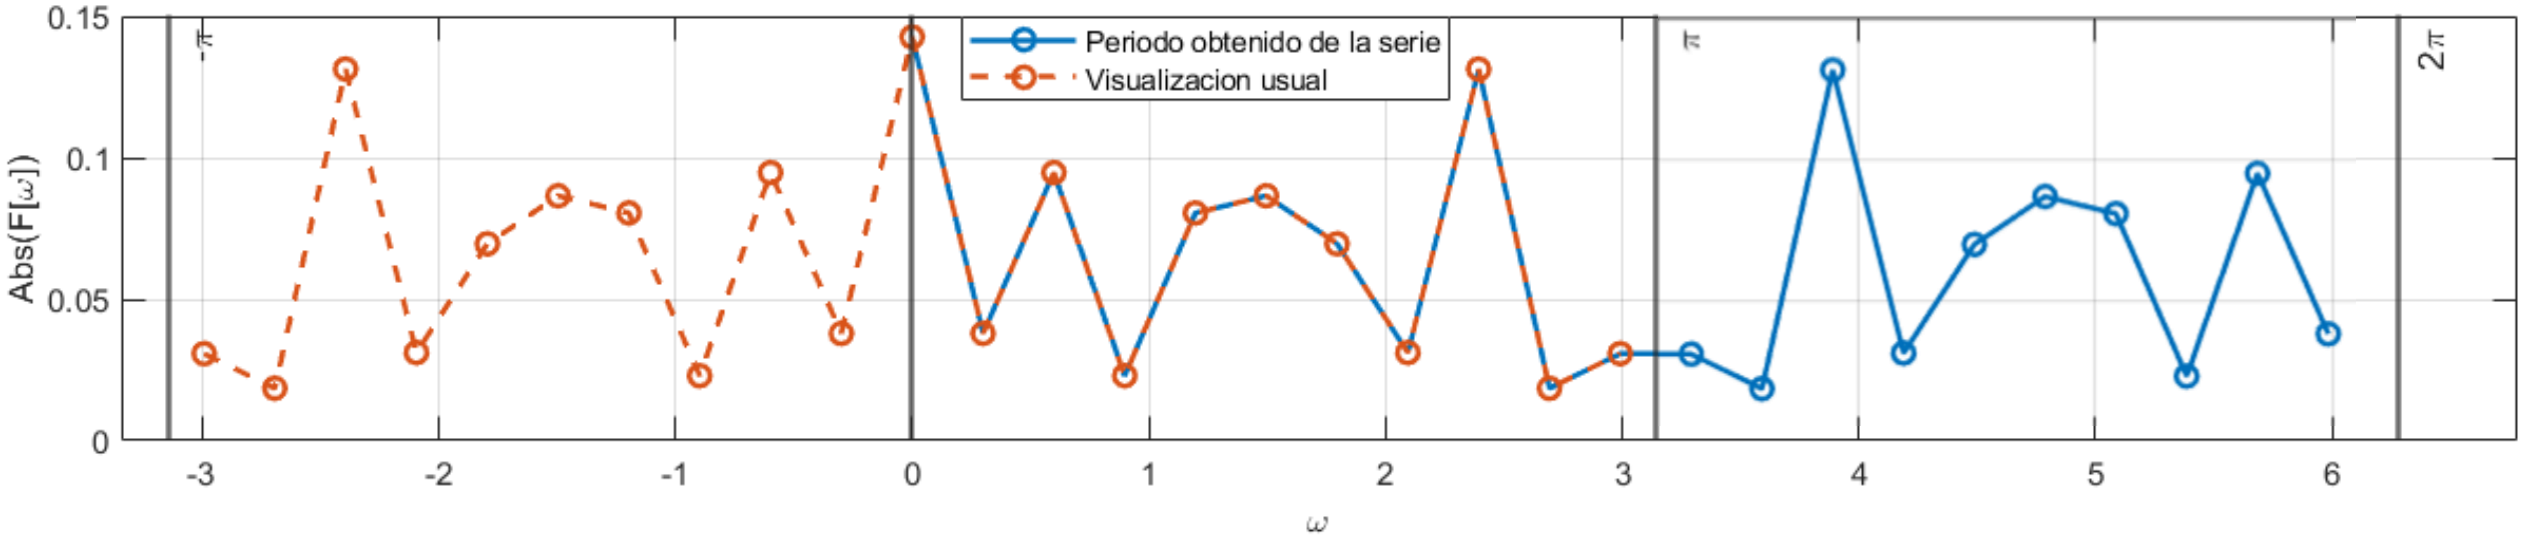
Los coeficientes $\boldsymbol{a_k}$ **tienen período N**. El espectro resulta periódico como se esperaba y definido completamente por **N** elementos.

- Si se renombra: $\omega = \frac{2\pi k}{N}$

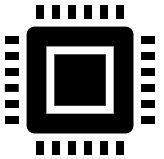
  Los coeficientes $\boldsymbol{a_\omega}$ son los valores en ω de la Transformada de Fourier Discreta (de período 2π) de una señal periódica.

Frecuencias en Tiempo Discreto

- Por facilidad computo los algoritmos generan los coeficientes a_k con k=0,…,N-1 por la conversión que vimos esto implica periodo de $[0,2\pi)$.
- Pero por otro lado, por su similitud a una Transformada de Fourier de Tiempo Continuo, usualmente se toma el periodo de $[-\pi,\pi)$.
- Por el teorema del muestreo esto equivale a $\left[-\frac{f_s}{2},\frac{f_s}{2}\right)$.



Transformada Rápida de Fourier



- Dadas las simetrías de la Transformada de Fourier, existe una familia de algoritmos para calcular rápidamente los valores en señales discretas. En particular, cuando N es potencia de 2, varias operaciones son computacionalmente mucho más simples.

- A estos algoritmos se los conoce como Fast Fourier Transform (FFT) y se encuentran en Matlab, Python y hasta integrado en microcontroladores y GPUs.

Ejemplo: La Ballena Solitaria

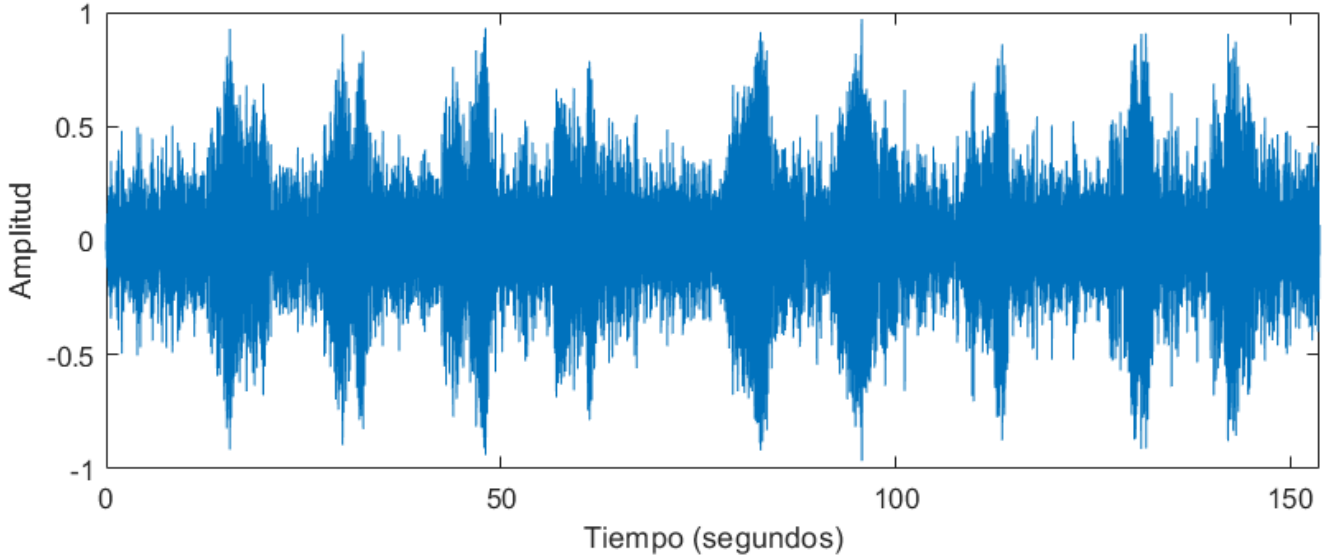
```
% x es el canto
% fs la frecuencia de muestreo
% N la cantidad de elementos

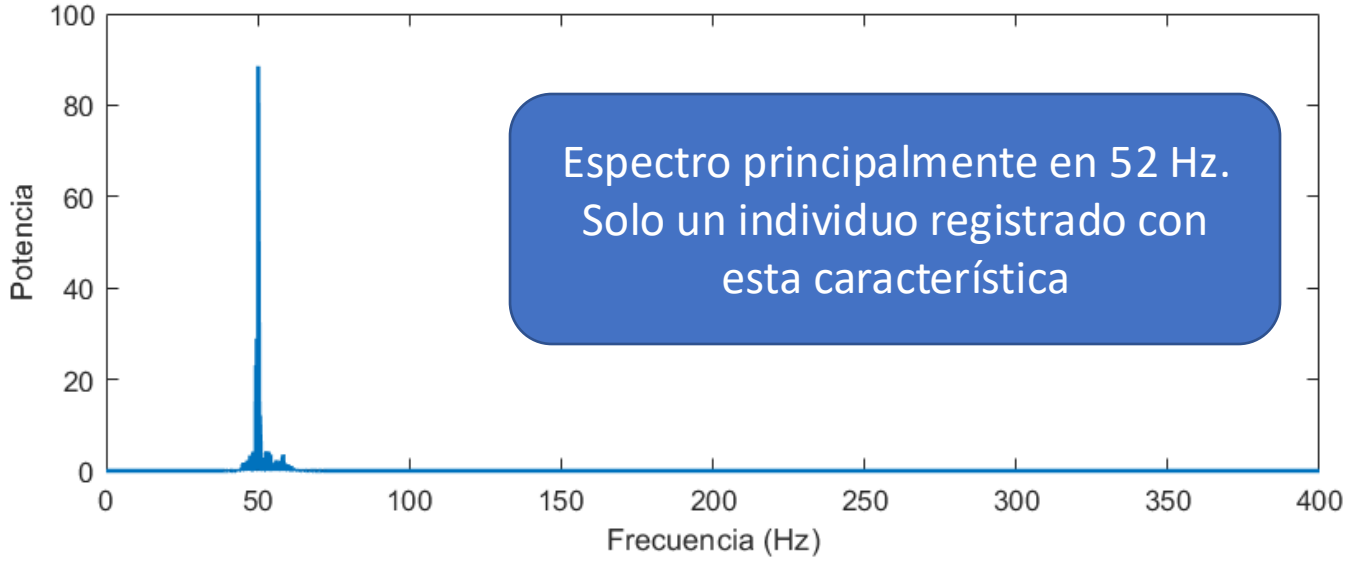
%calculo de la fft
a = fft(x);

%calculo la potencia para cada frecuencia
power = abs(a).^2/N;

%calculo las frecuencias que genera la fft:
% (0:N-1) *  (2pi/N)  * (fs / 2pi) ;
f = (0:N-1)*(fs/N); %simplifico

fpos = 1:floor(N/2); %solo frecuencias positivas
plot(f(fpos), power(fpos))
```



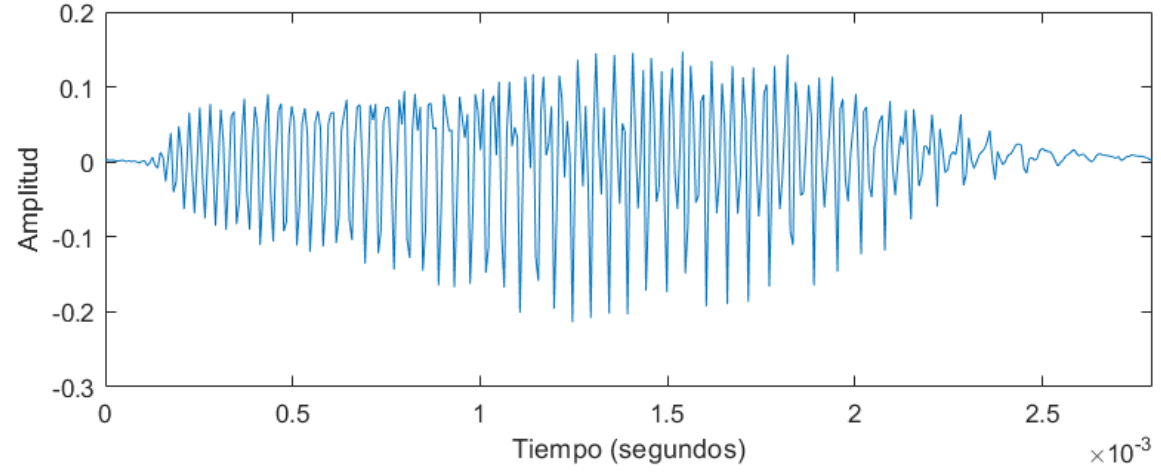


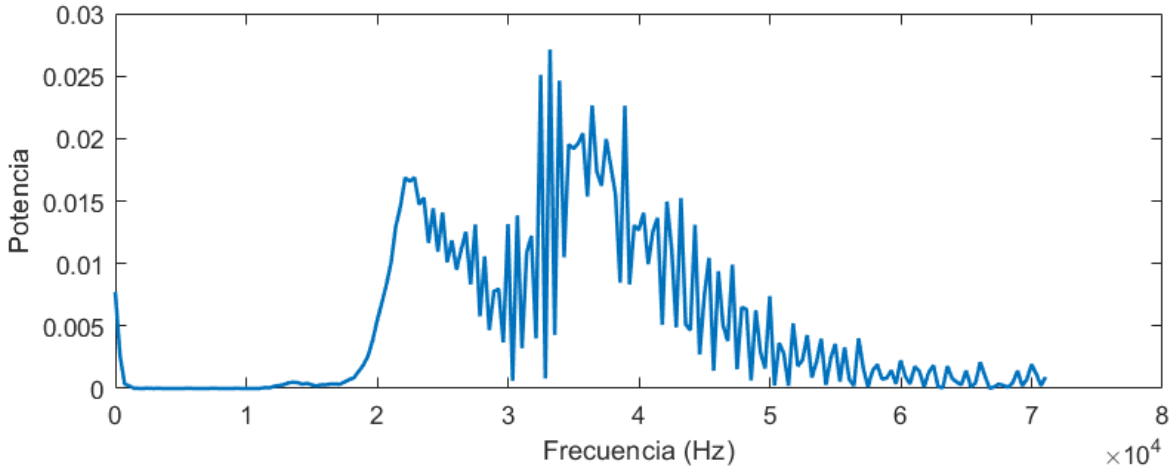
https://es.wikipedia.org/wiki/Ballena_de_52_hercios

Limitaciones de Fourier: Ecolocación

- Ejemplo con señal de ecolocación de un murciélago. Dado su uso, este tipo de señal tiene una relación compleja entre tiempo y frecuencia.

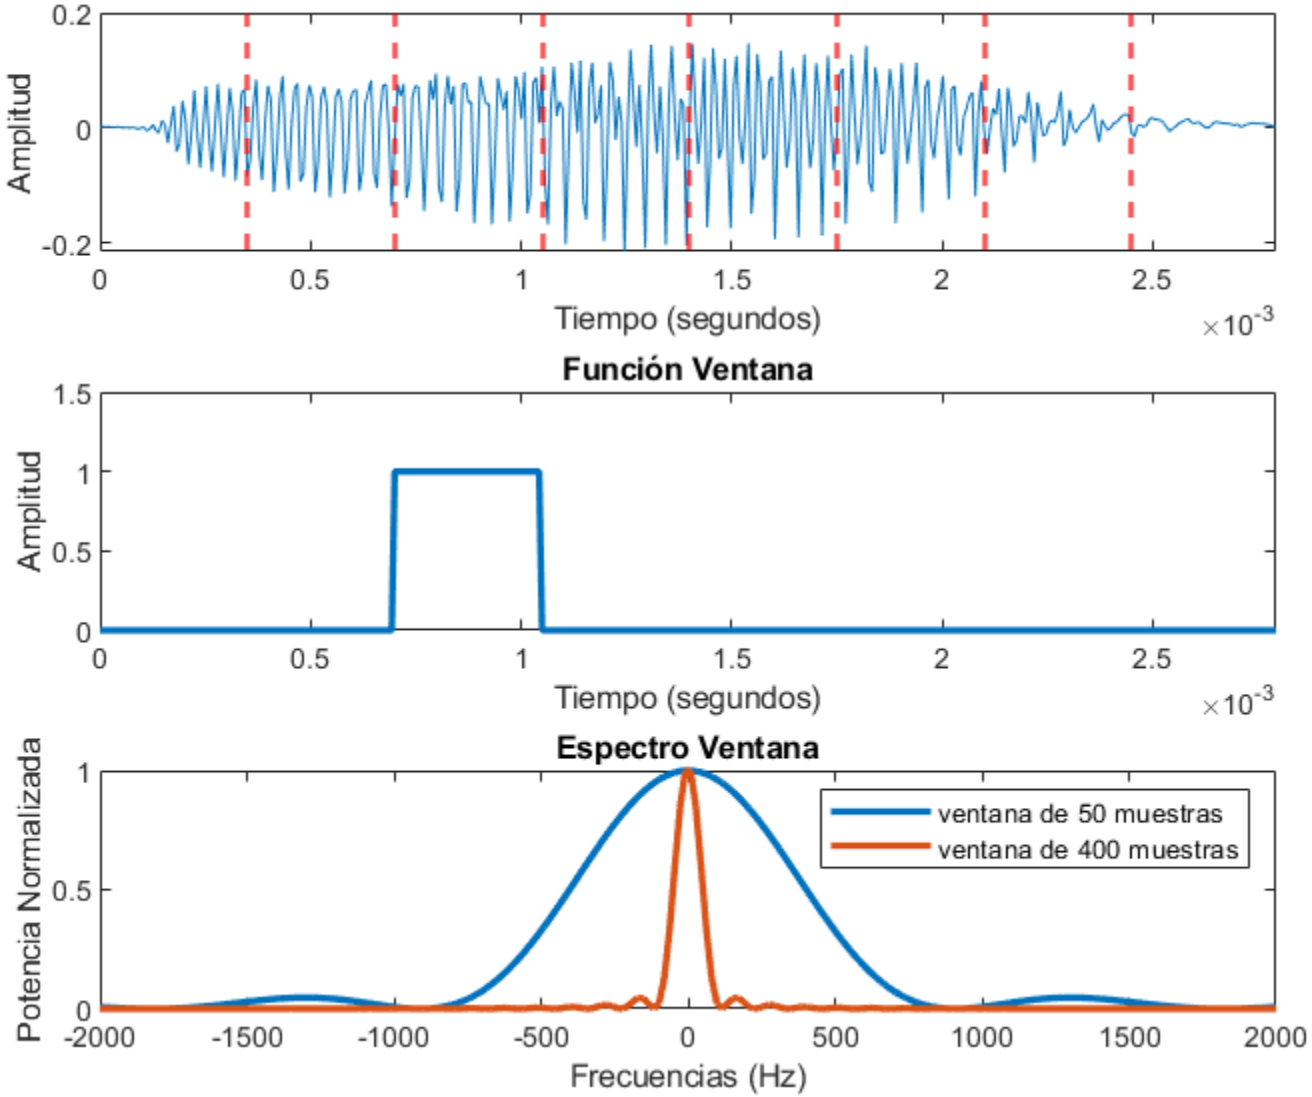
- Cuando se quiere observar la dependencia temporal del espectro, la FFT no es suficiente.





Transformada de Fourier de Corto Tiempo (1)

- Una solución es aplicar la FFT en segmentos de la señal.
- La FFT en cada segmento tiene menos elementos, lo que implica que su espectro también pierde resolución.
- Idea alternativa: multiplicar la señal por una ventana de M elementos, implica convolucionar el espectro por una sinc de lóbulo principal de ancho $2\ f_s/M$. Esto genera más valores de frecuencia pero contaminados por sus vecinos.

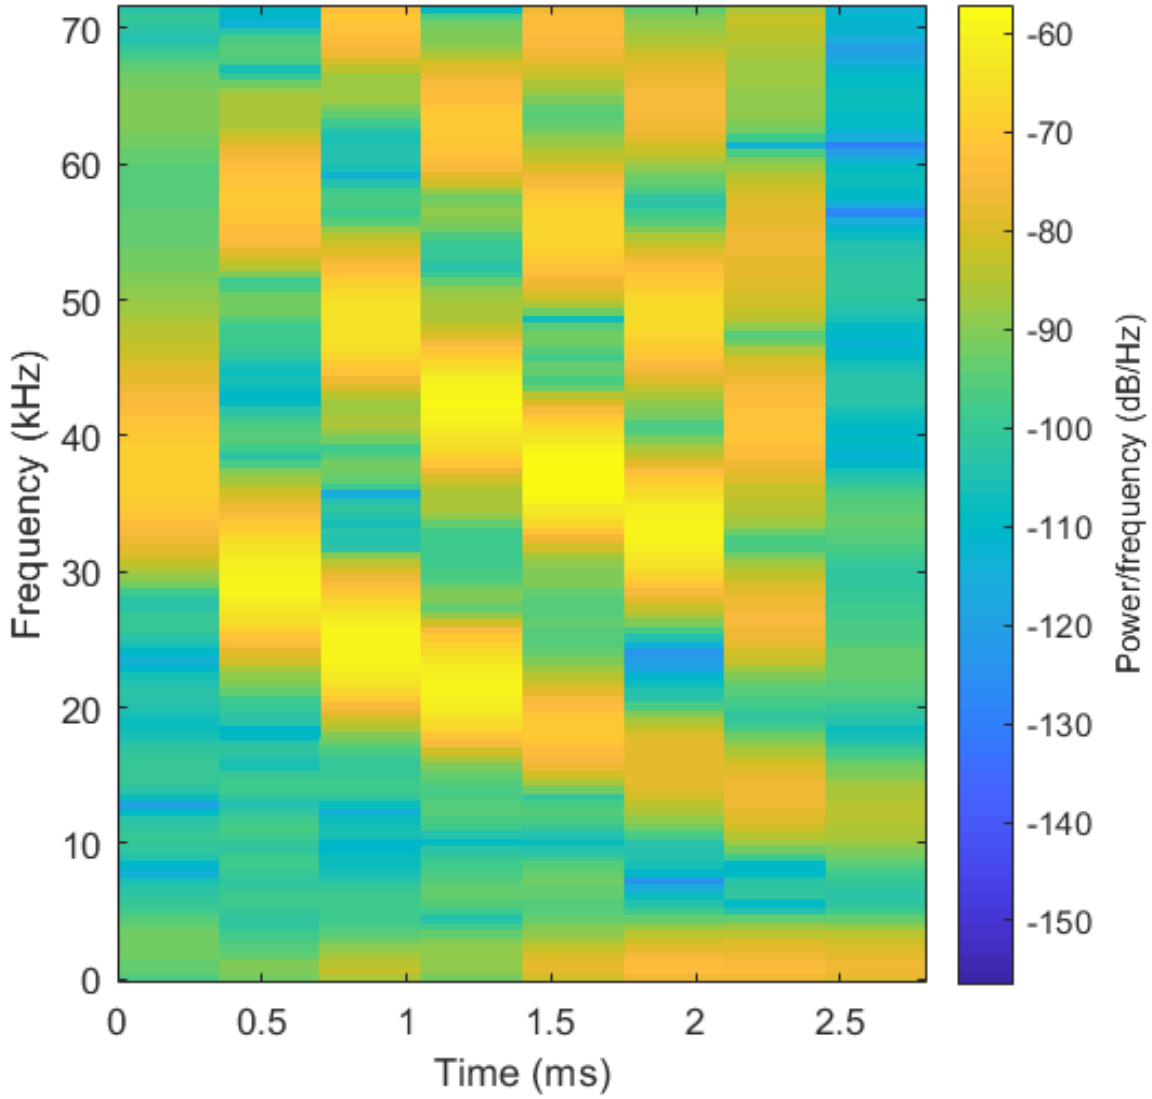


Transformada de Fourier de Corto Tiempo (2)

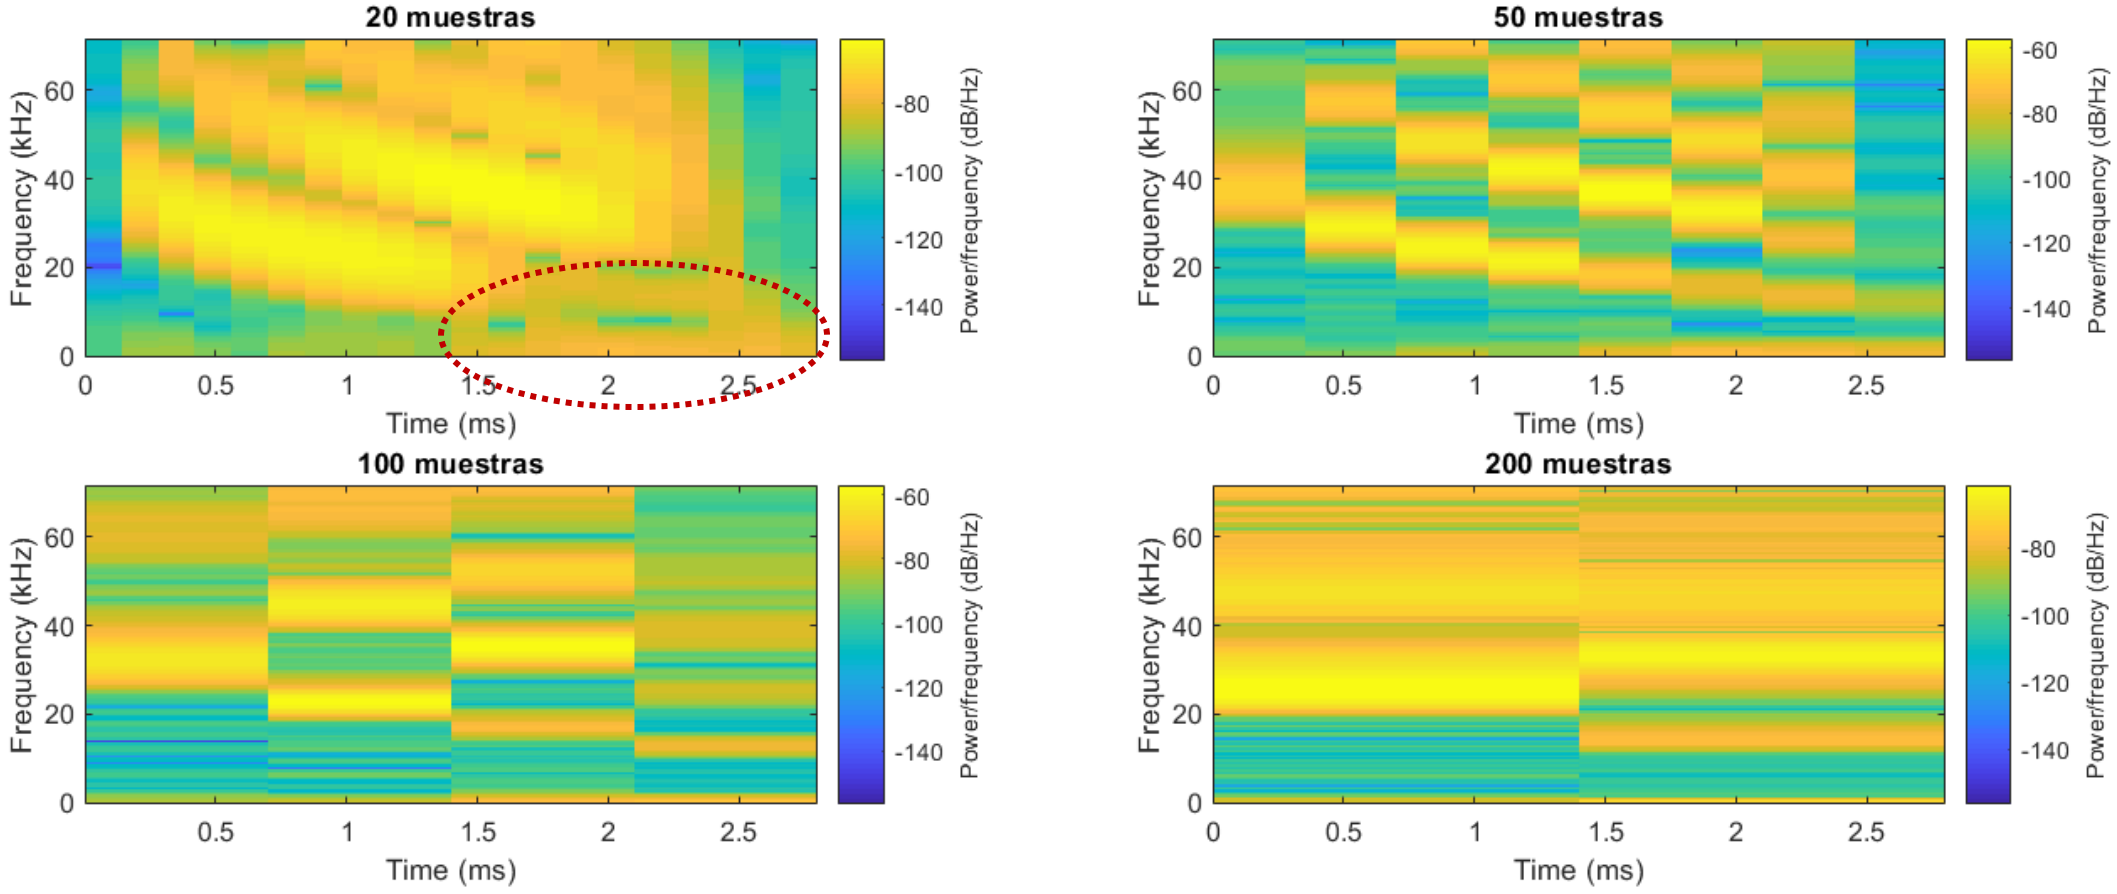
```
% batsignal es el sonido
% fs la frecuencia de muestreo
% uso  25 de elementos en cada segmento
%genero el espectrograma
spectrogram(batsignal,25,0,[],fs,'yaxis')
```

El grafico resultante es un espectrograma. Cada columna (ventana de tiempo) es la mitad positiva de una FFT.

Recordar que en cada ventana el espectro tiene realmente solo la información de 12 frecuencias.



Transformada de Fourier de Corto Tiempo (3)



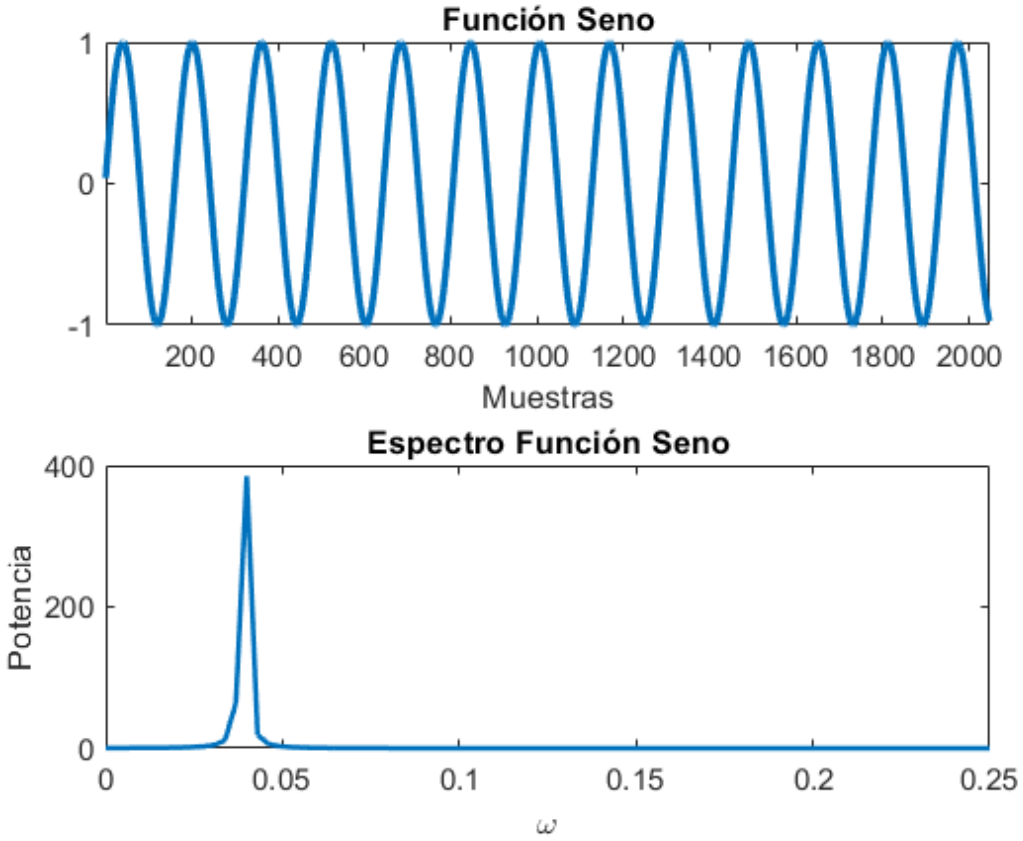
A mayor resolución en tiempo menos en frecuencia

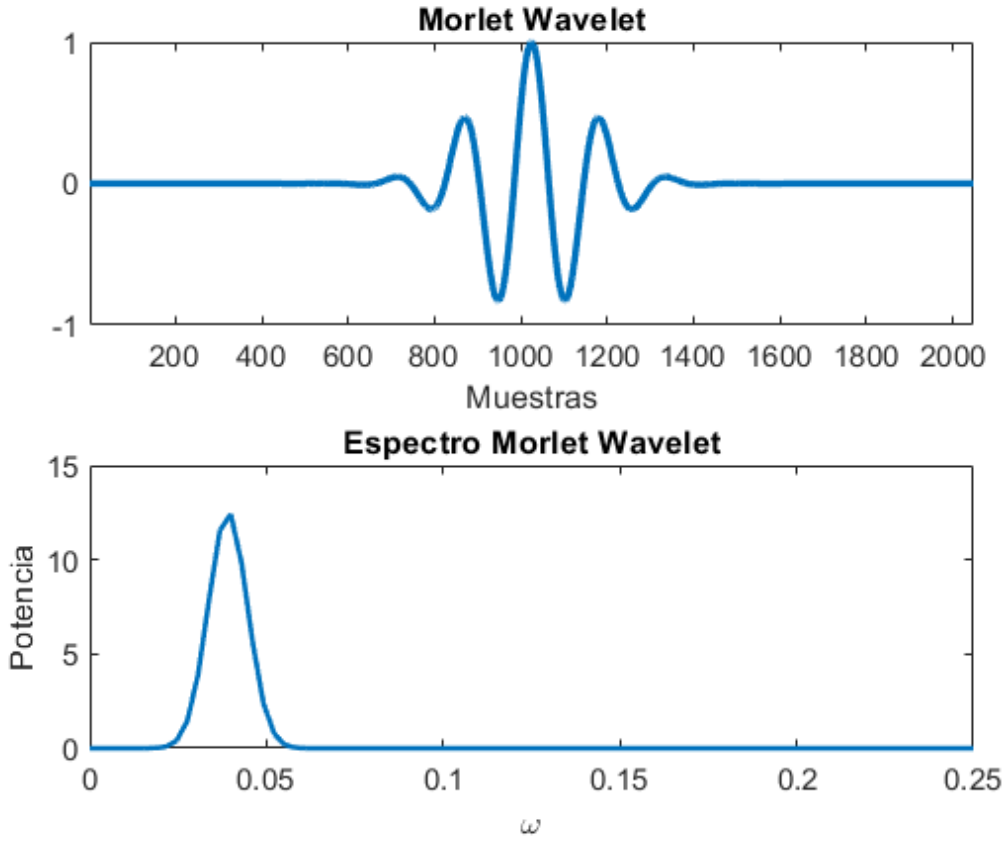


Transformada Wavelet Continua (CWT)

El código de los gráficos de esta sección están en wv_cont.m

Idea conceptual detrás de la CWT





- Fourier se basa en funciones que no están limitadas temporalmente.
- Las wavelets tienen limitado tanto su espectro como su duración.

Idea conceptual detrás de la CWT (2)

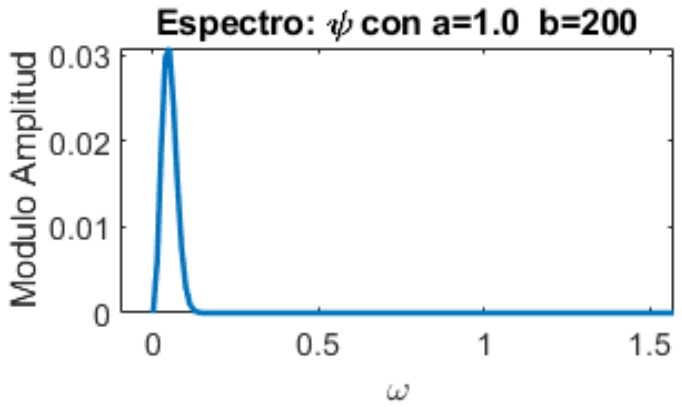
Necesitamos que la wavelet cubra todos los tiempos y todas las frecuencias.

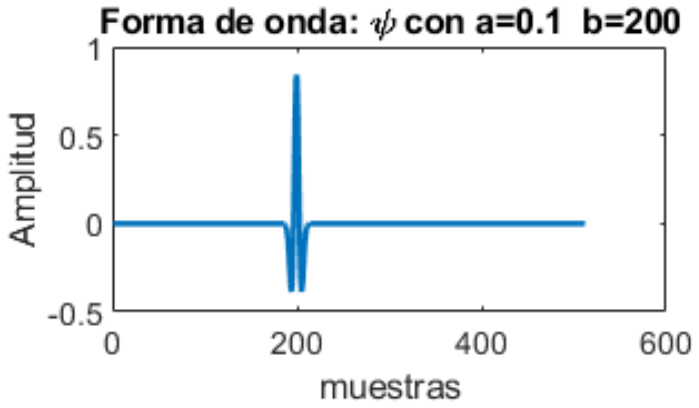
Ejemplo con wavelet *Sombrero Mexicano*.

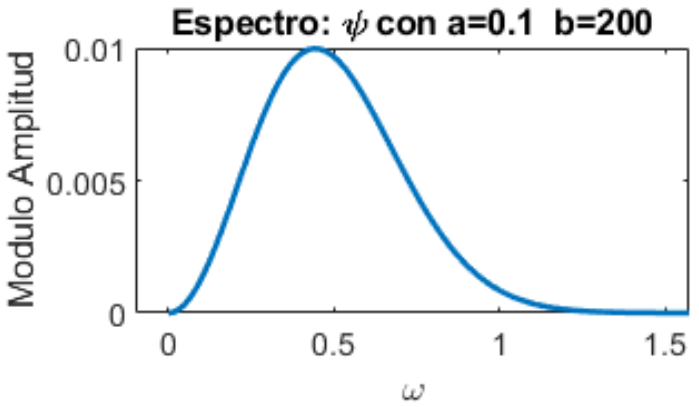
$$\psi_{a,b}(t) = \psi_0^*\left(\frac{t-b}{a}\right)$$

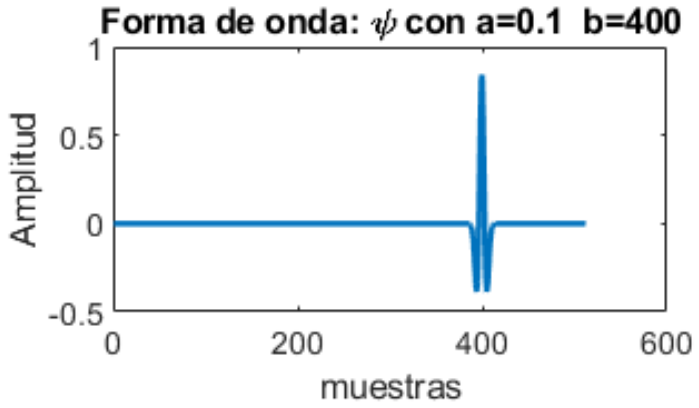
Wavelet madre

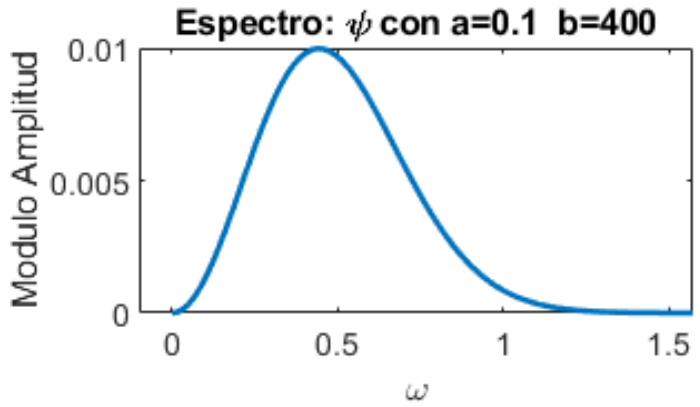






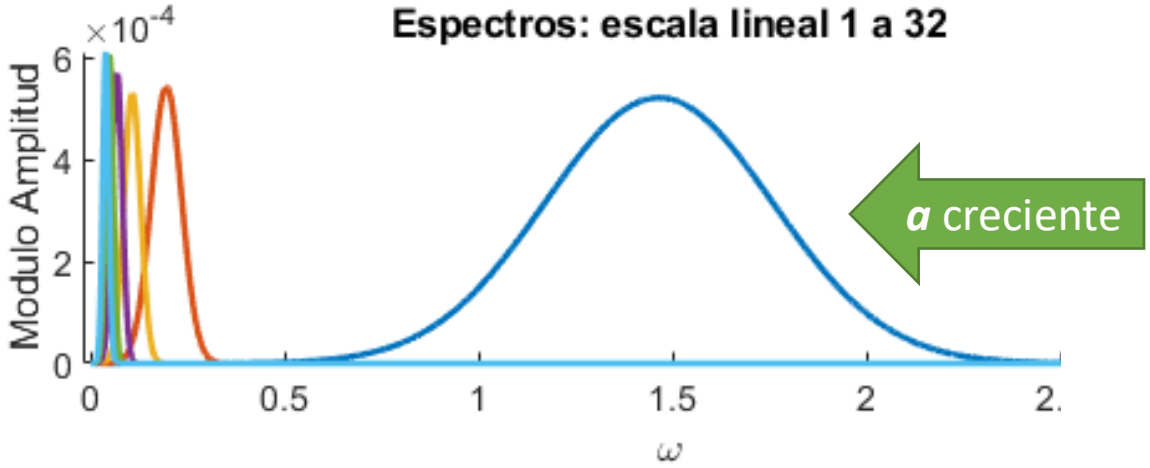


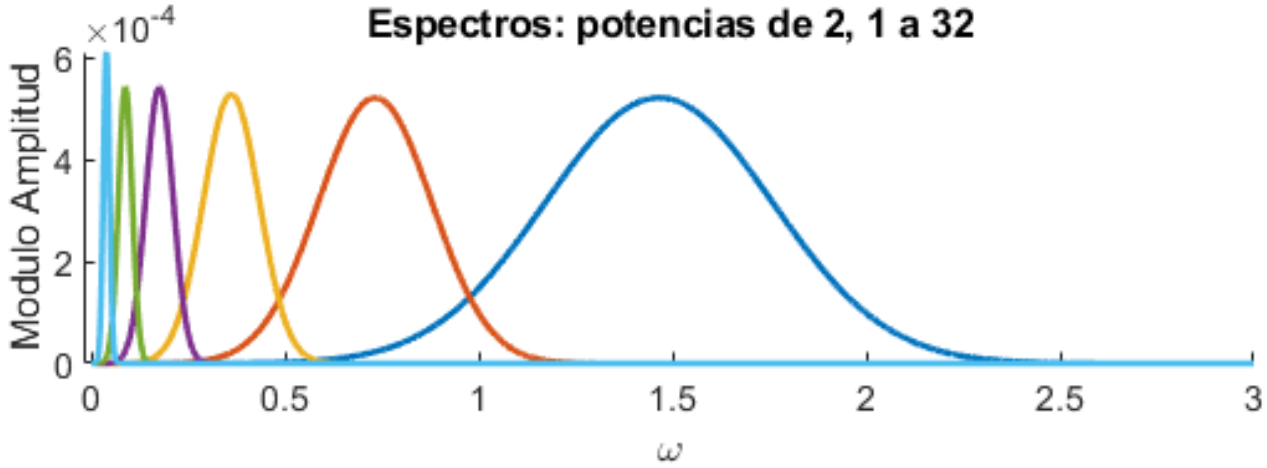




Comentarios Sobre Escalas (1)

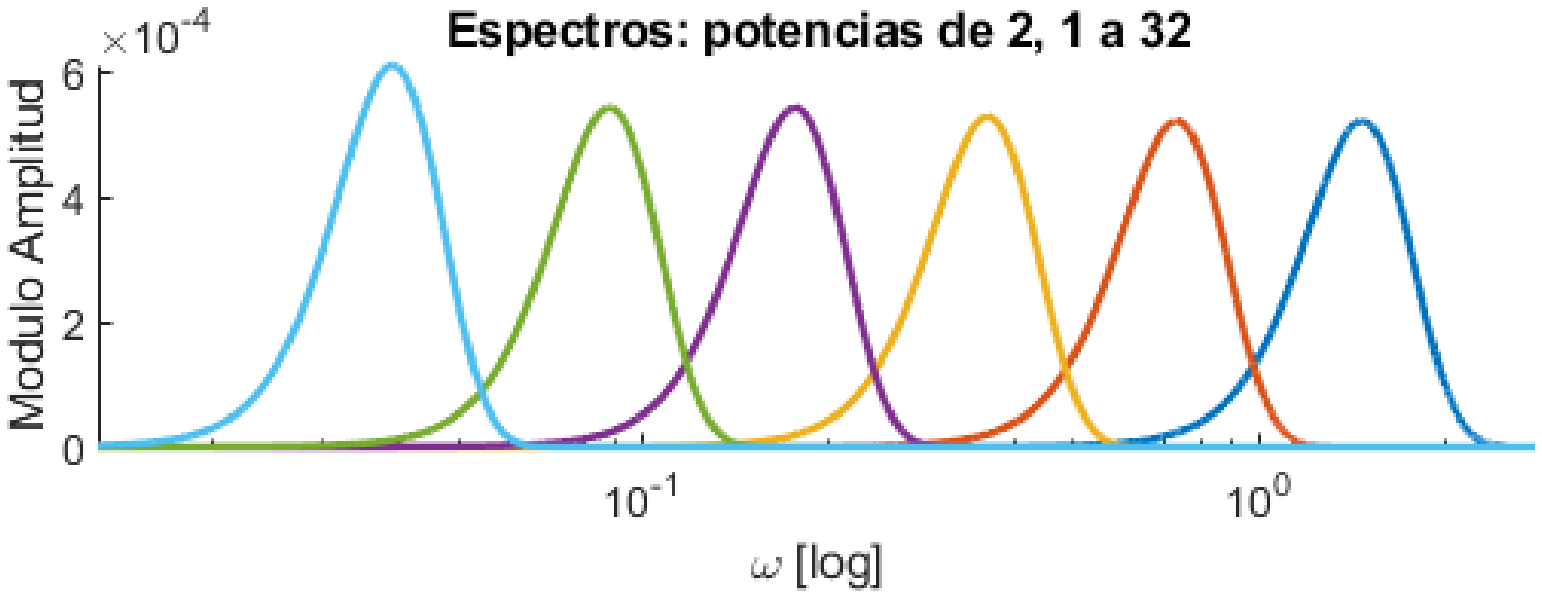
- Al expandir en tiempo la wavelet (↗a), el lóbulo de su espectro se contrae y su pico pasa a menores frecuencias.
- Es importante seleccionar escalas para que los espectros no se superpongan y se exploren todas las frecuencias.
- Utilizar escalas de la forma $a = a_0 2^c$ cubre mejor las frecuencias que una escala lineal.





Comentarios Sobre Escalas (2)

- La escala logarítmica simplifica la visualización de los resultados.



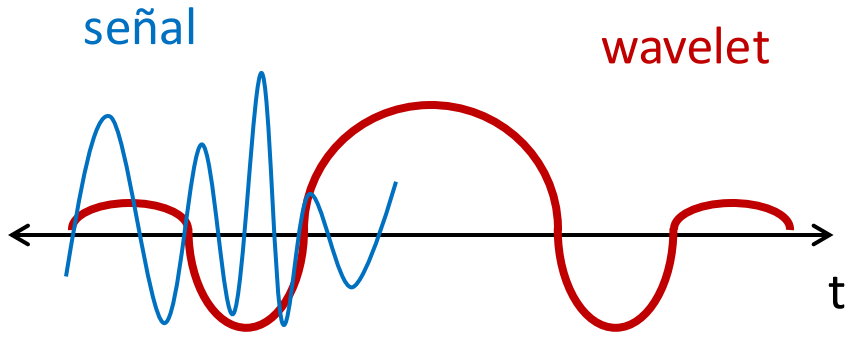
- La relación particular entre escala (a) y pico del espectro depende de la wavelet madre utilizada.

Comentarios Sobre Escalas (3)

Escala Máxima

- A partir de cierta escala el largo de la wavelet supera al de la señal, por lo que el valor obtenido pierde validez.
- A grandes escalas, al desplazar la wavelet, parte de su forma de onda queda fuera del largo de la señal, por lo tanto tampoco es fiable.

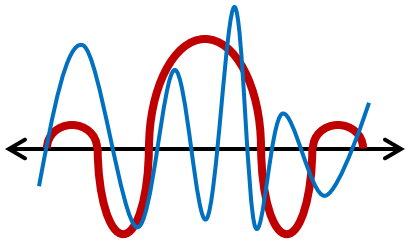
Ejemplo de escala demasiado grande:



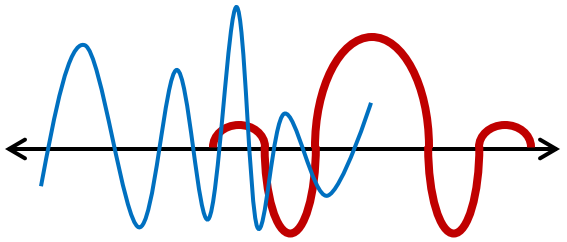
Escala Mínima

- Recordar que al superar la f_{nyq} el espectro pierde significado.
- Matlab permite reducir la escala hasta que una pequeña porción del espectro supere la f_{nyq}.

Ejemplo valido:



Ejemplo con demasiado desplazamiento:



Transformada Wavelet Continua

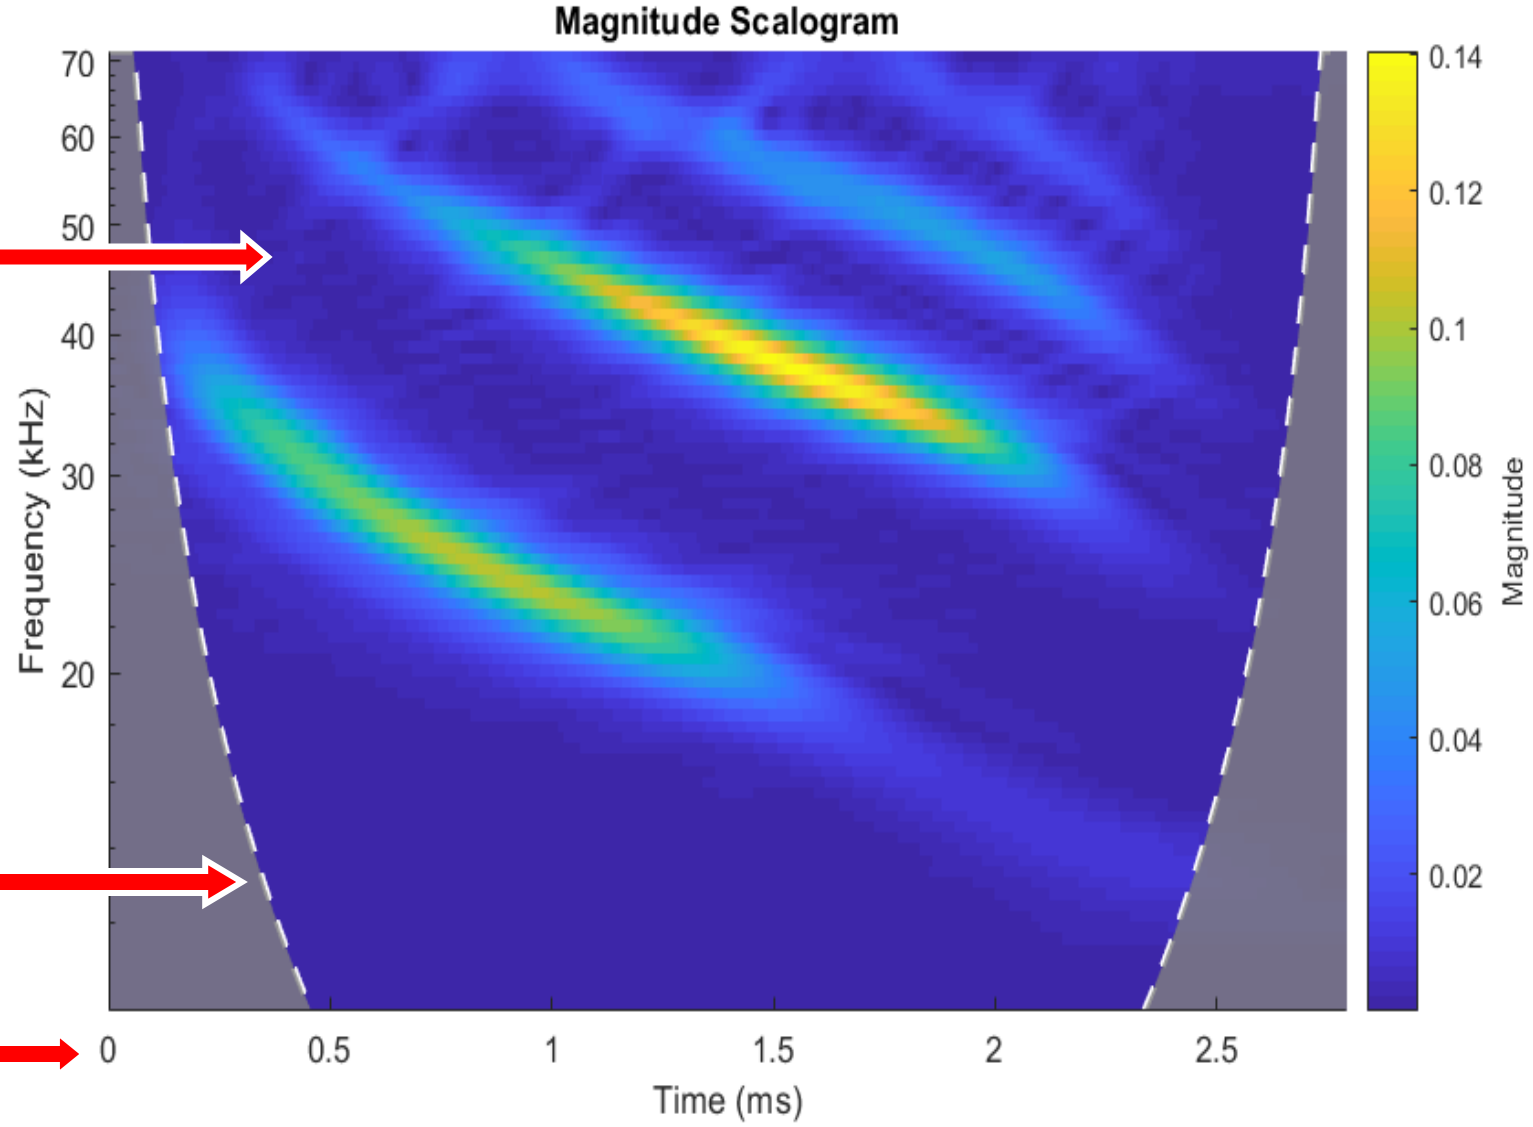
Cada pixel del escalograma es una solución:

$$F_{a,b} = \int_{-\infty}^{\infty} f(t) \frac{1}{\sqrt{a}} \psi_0^* \left(\frac{t-b}{a} \right) \mathrm{d}t$$

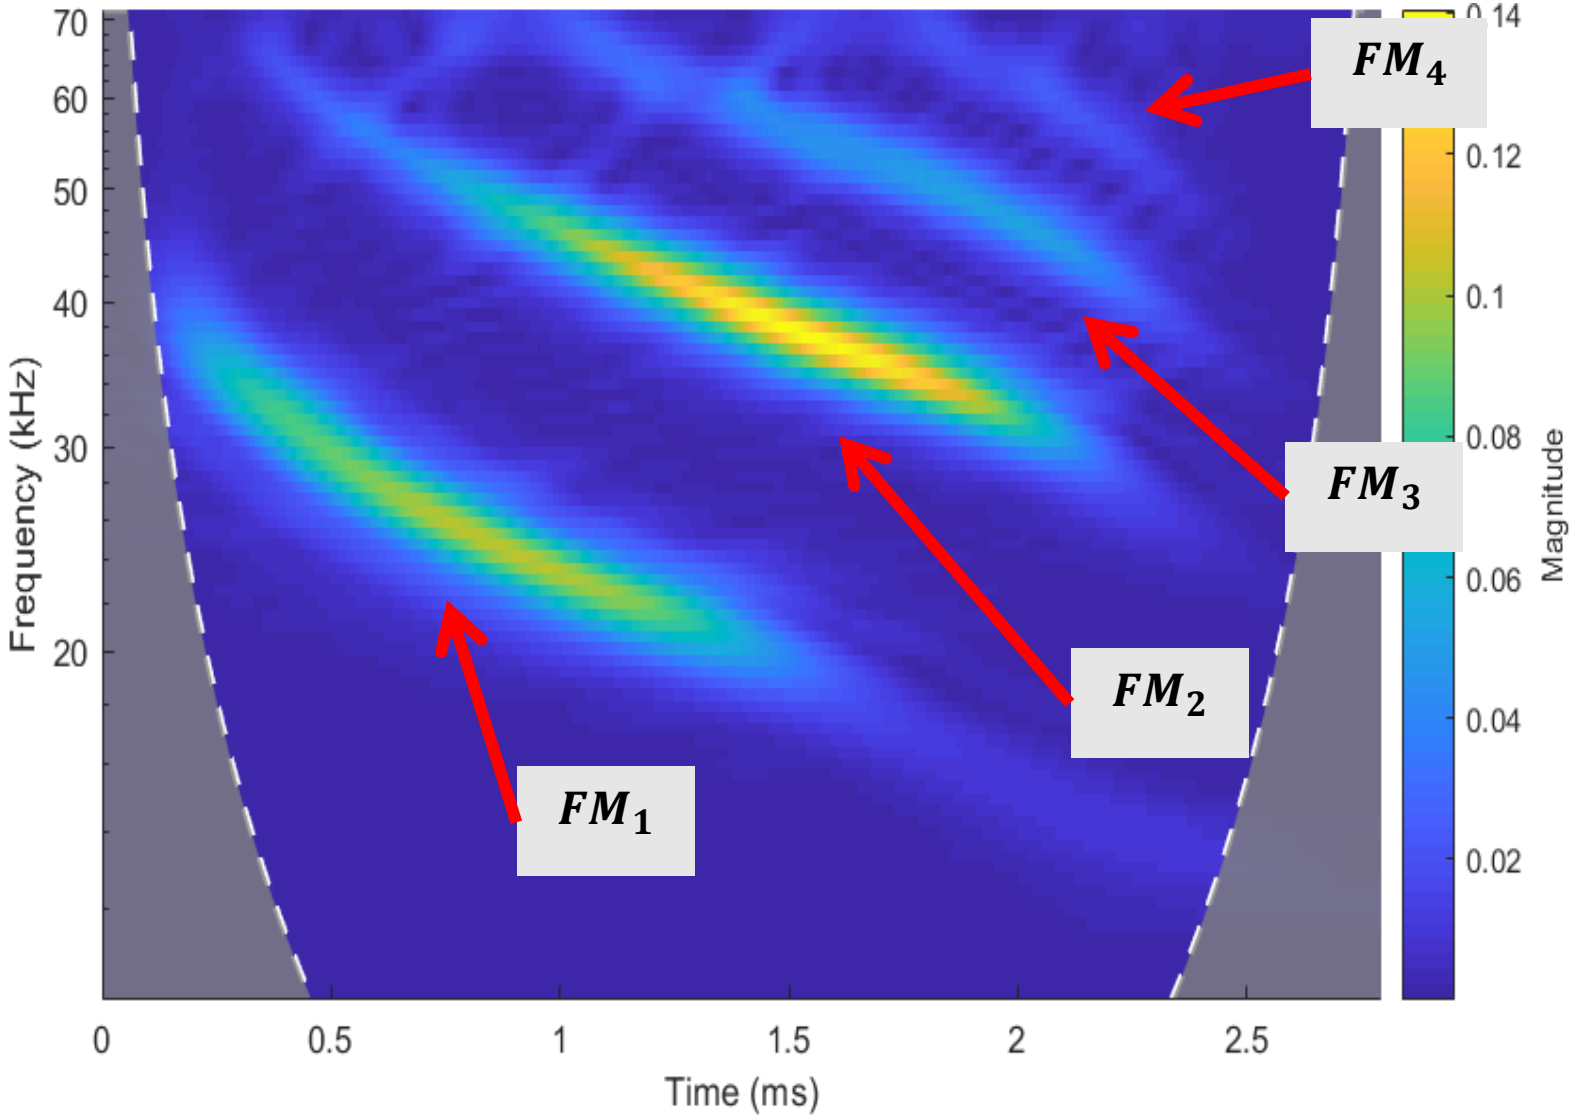
Escala logarítmica en las frecuencias (escalas **a**)

Zona donde la Wavelet esta dentro del tiempo de la señal (Cono de Influencia).

Desplazamientos **b**



Ecolocación

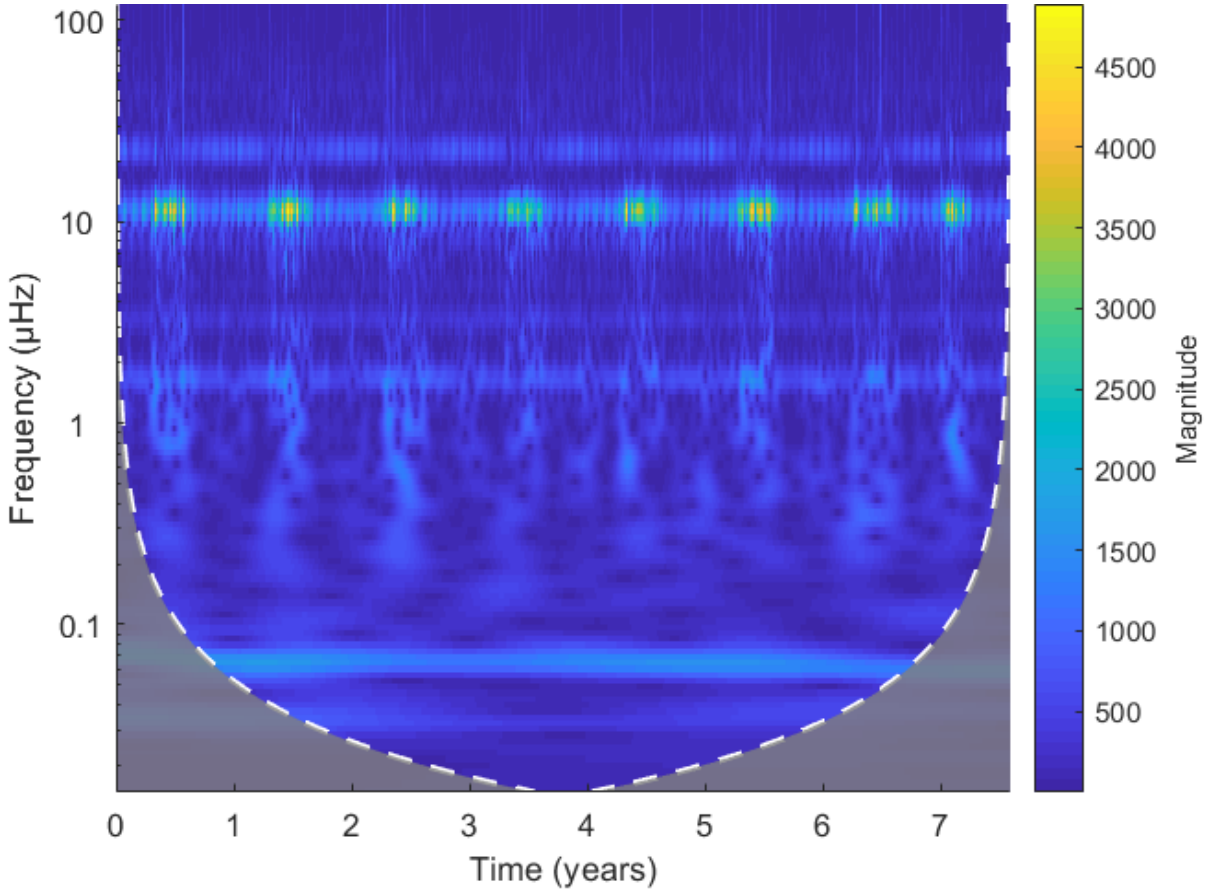


- El grafico muestra 4 señales de frecuencia modulada (FM) típico en animales que utilizan ecolocación.
- Existen neuronas “especialistas en FM” que responden particularmente a este tipo de estimulo.
- Para minimizar la interferencia los murciélagos pueden modificar las frecuencias limites de sus FM.

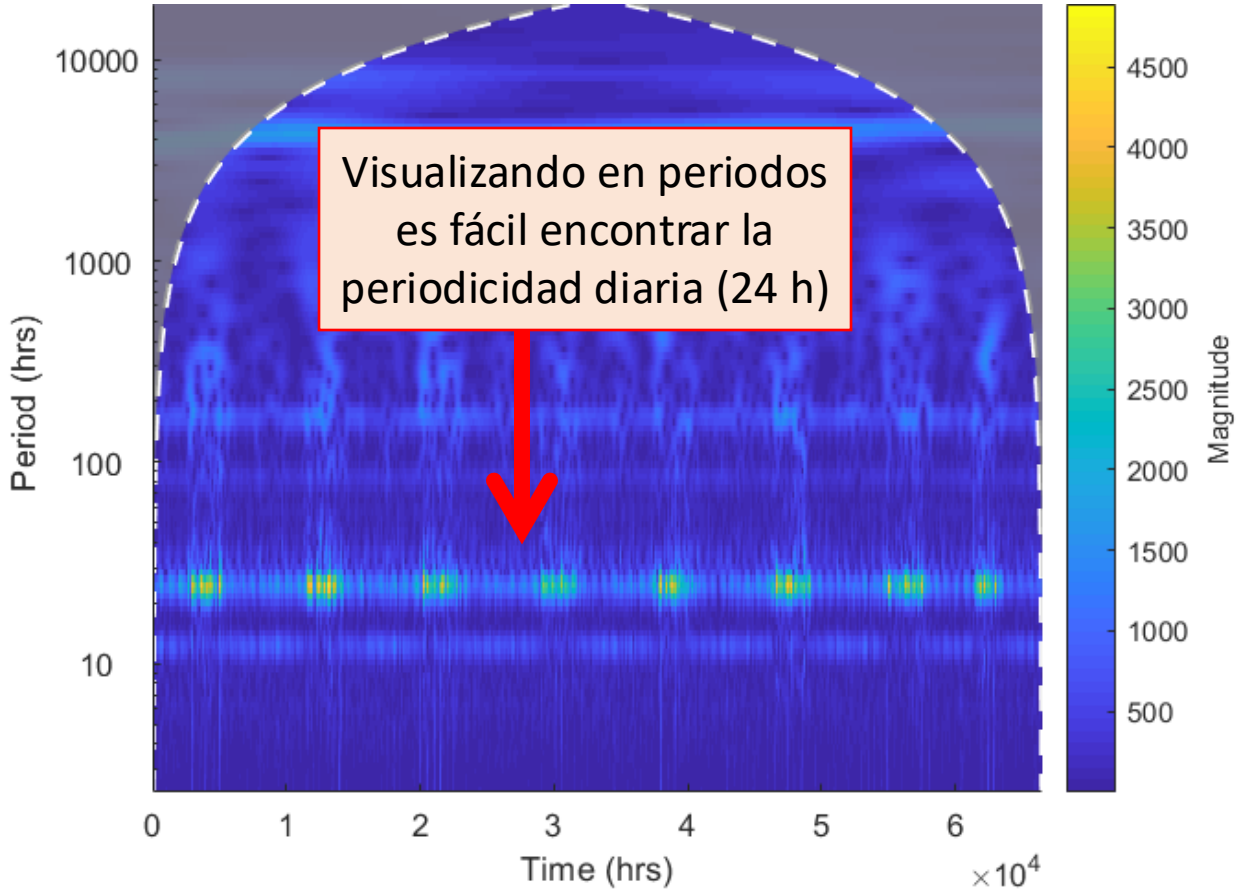
Ejemplo: Consumo de Energía (1)

Registro durante 7 años de consumo energético en MW (EEUU). Una muestra por hora.

cwt(x,'morse',1/(60*60))



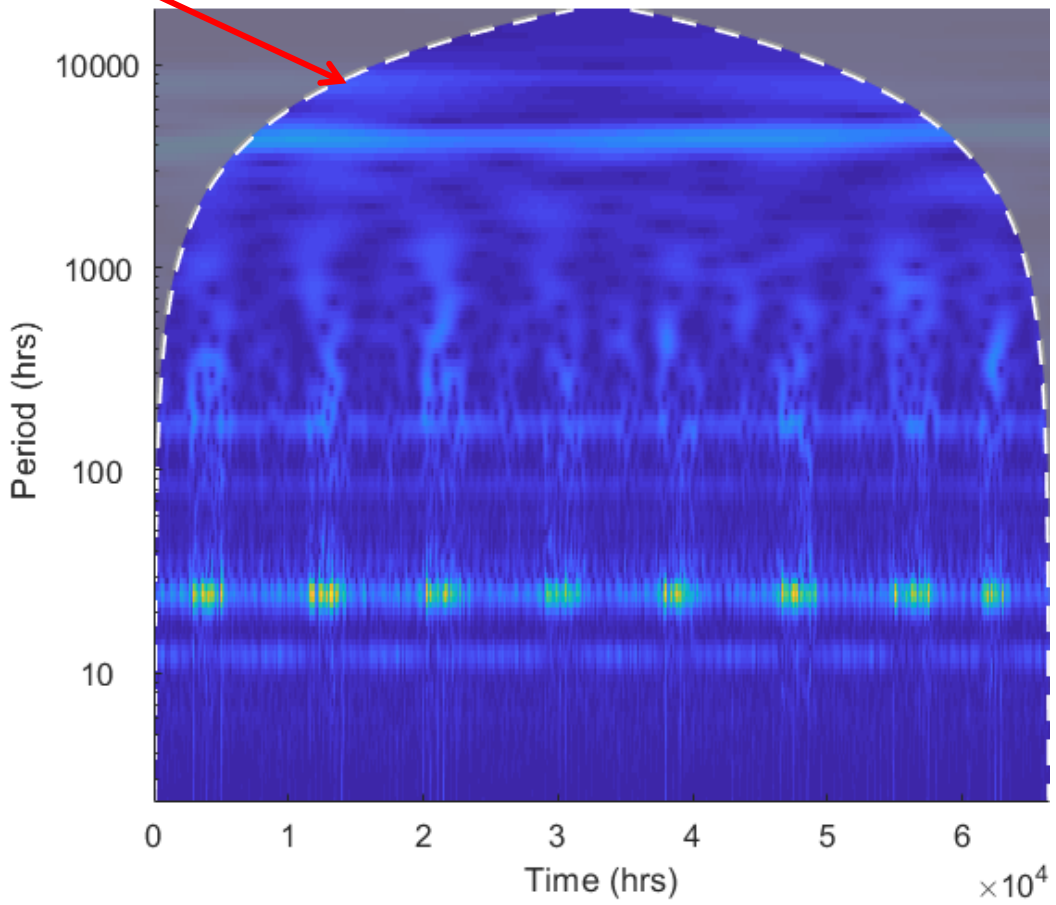
cwt(x,'morse',hours(1))



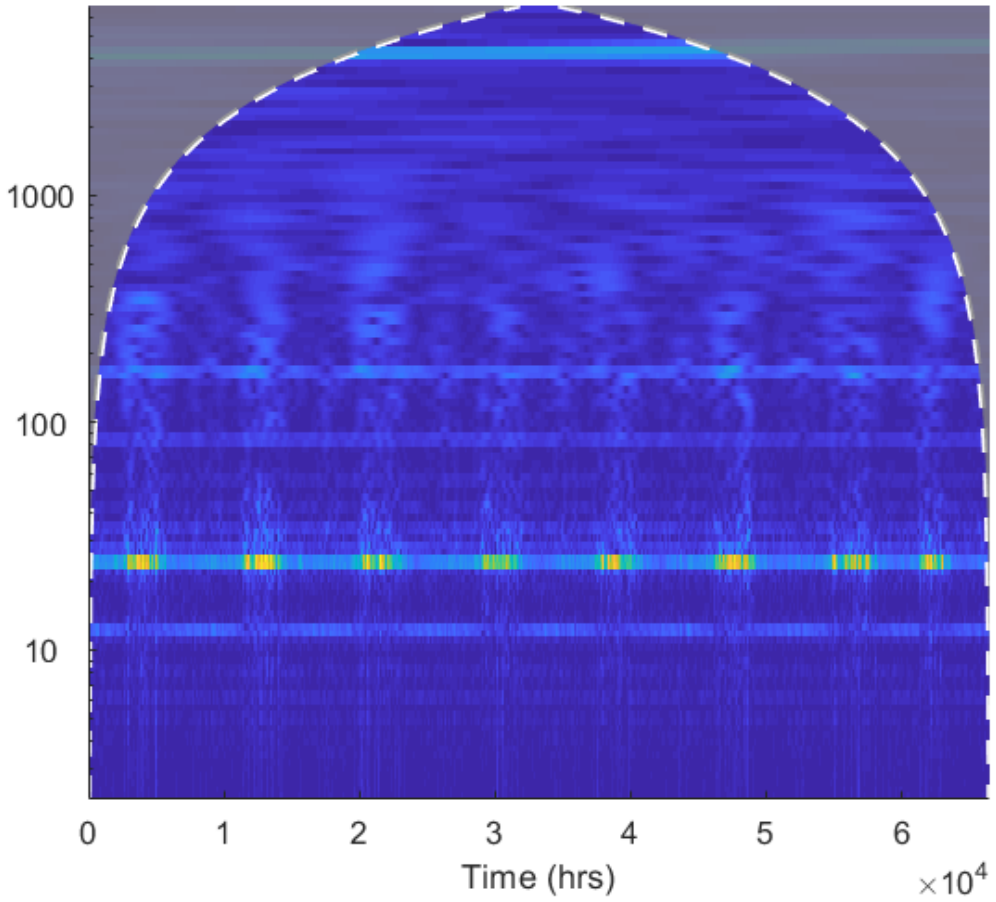
Ejemplo: Consumo de Energía (2)
Cambio de Wavelet

365 días

cwt(x,'morse',hours(1))



cwt(x,'bump',hours(1))



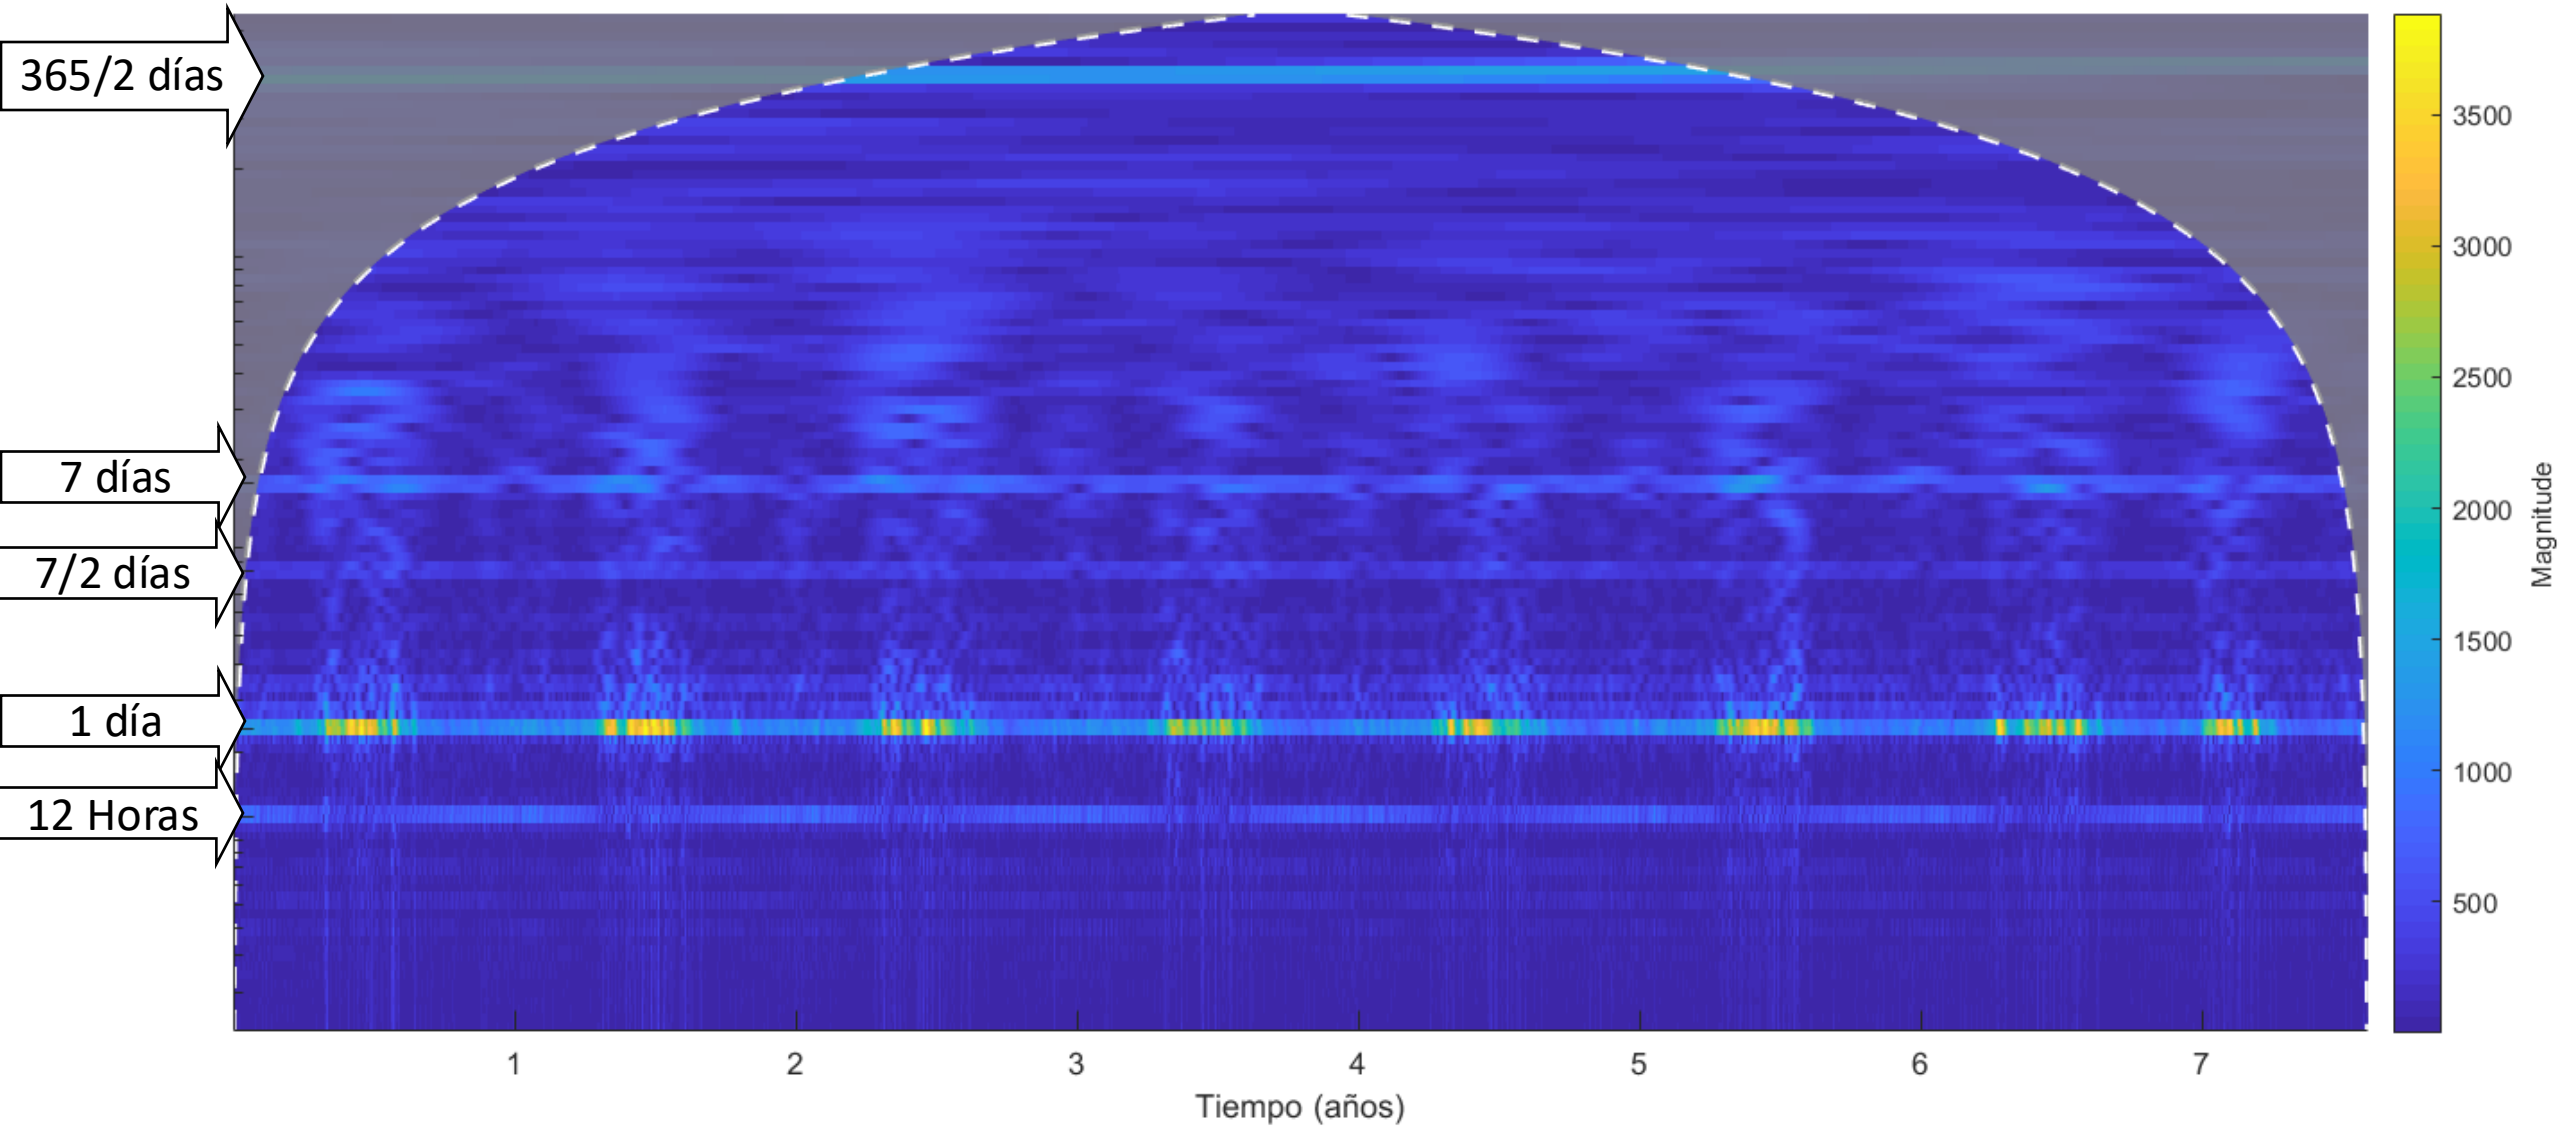
Diferencias

- Eje de periodos (Notar la desaparición de la oscilación más lenta)

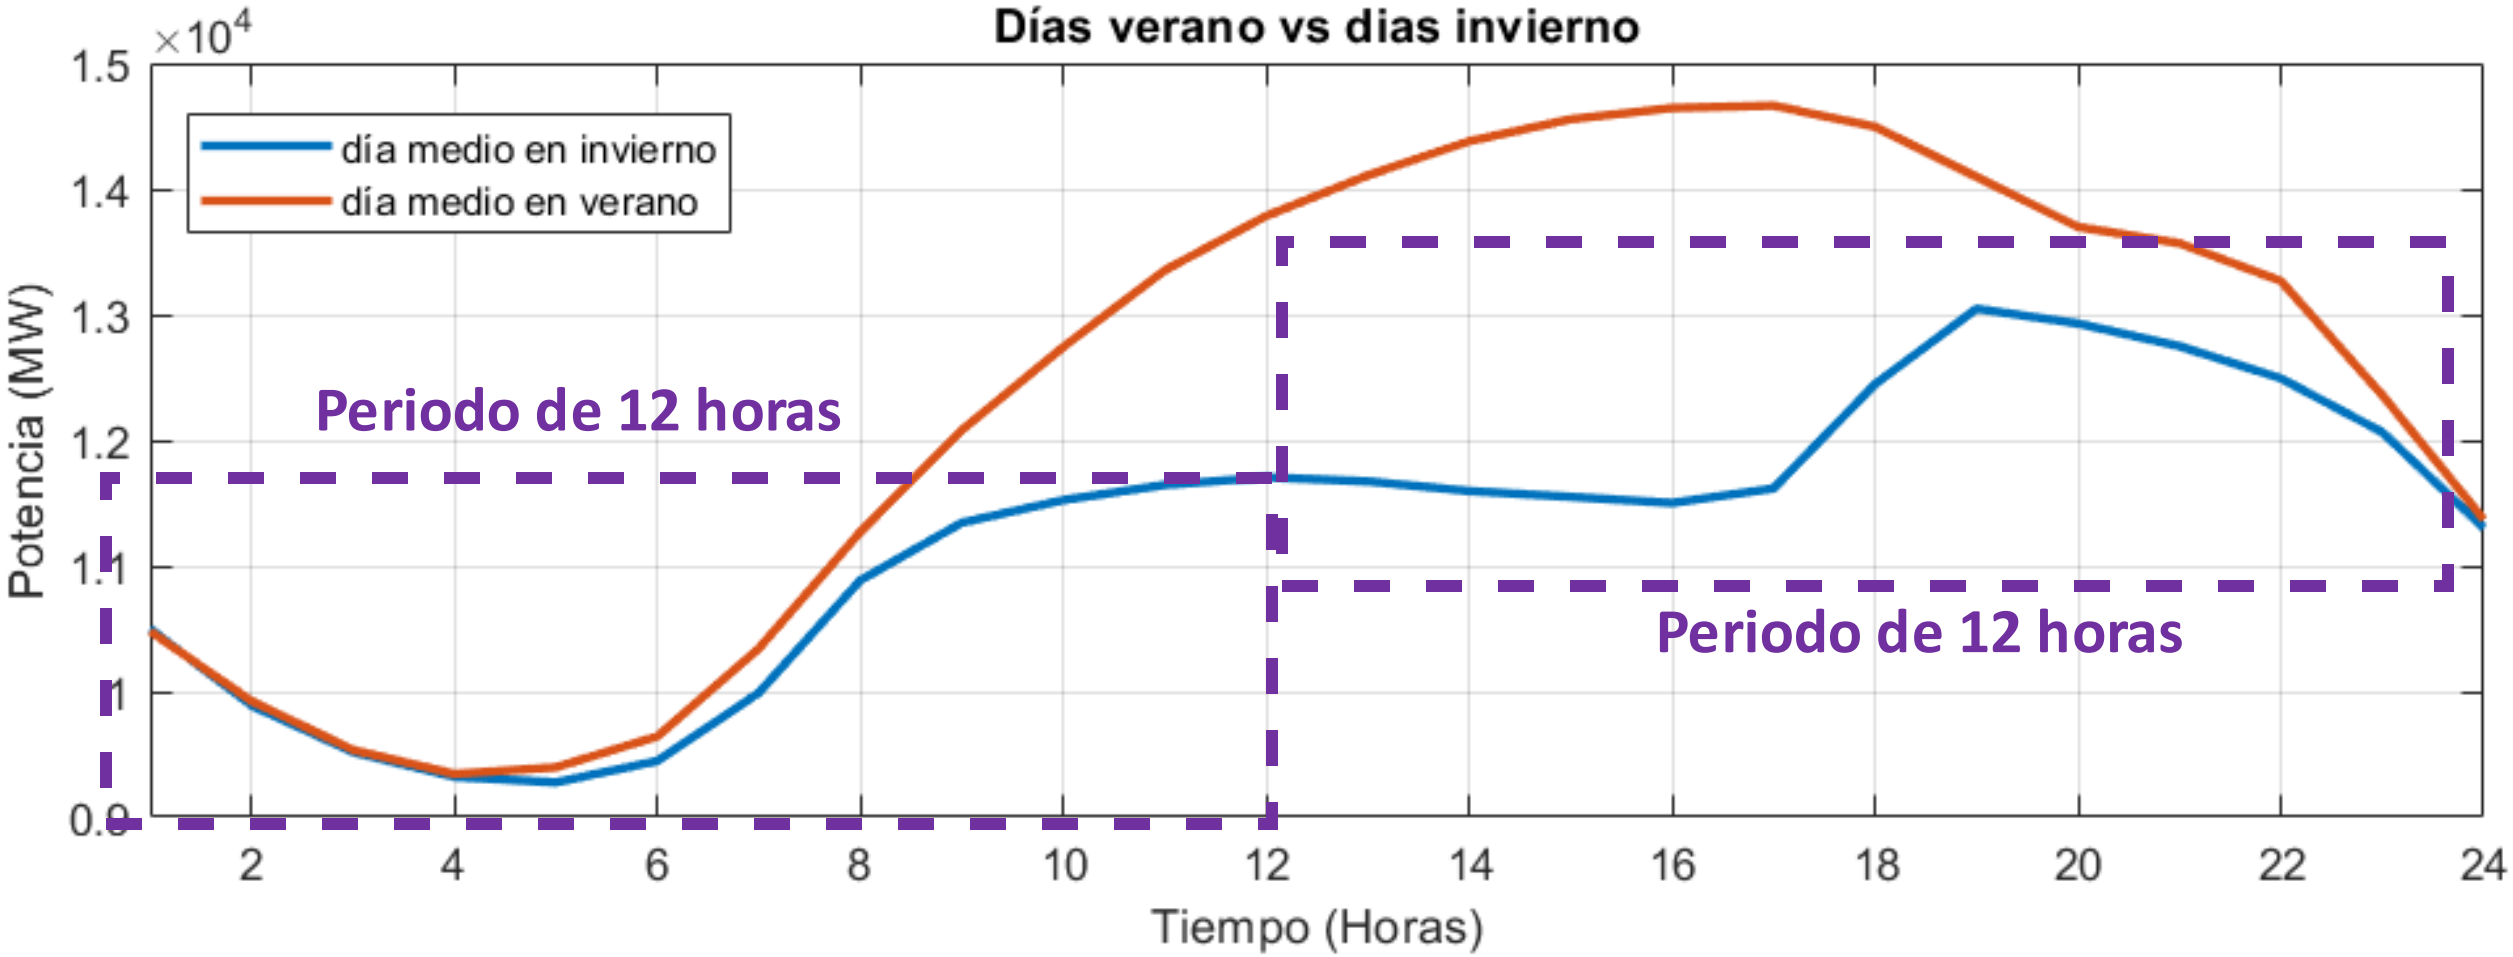
- Precisión en tiempo y frecuencia.

- Cono de influencia

Ejemplo: Consumo de Energía (3)



Ejemplo: Consumo de Energía (4)





Transformada Wavelet Discreta (DWT)

El código de los gráficos de esta sección están en wv_disc.m

Idea conceptual detrás de la DWT (1)

- La CWT obtiene, por escala, una señal del largo de la señal original. La misma información podría expresarse en menos coeficientes.
- Por ejemplo con altas escalas, son pocos los desplazamientos que están dentro del cono de influencia.
- Se busca utilizar las wavelets como una base ortogonal para describir la señal.
- La **Transformada Wavelet Discreta** utiliza la cantidad mínima de coeficientes wavelets (N) para contener la información de la señal. Debido a sus propiedades la DWT puede optimizarse de forma tal que su costo computacional es reducido.

Idea conceptual detrás de la DWT (2)

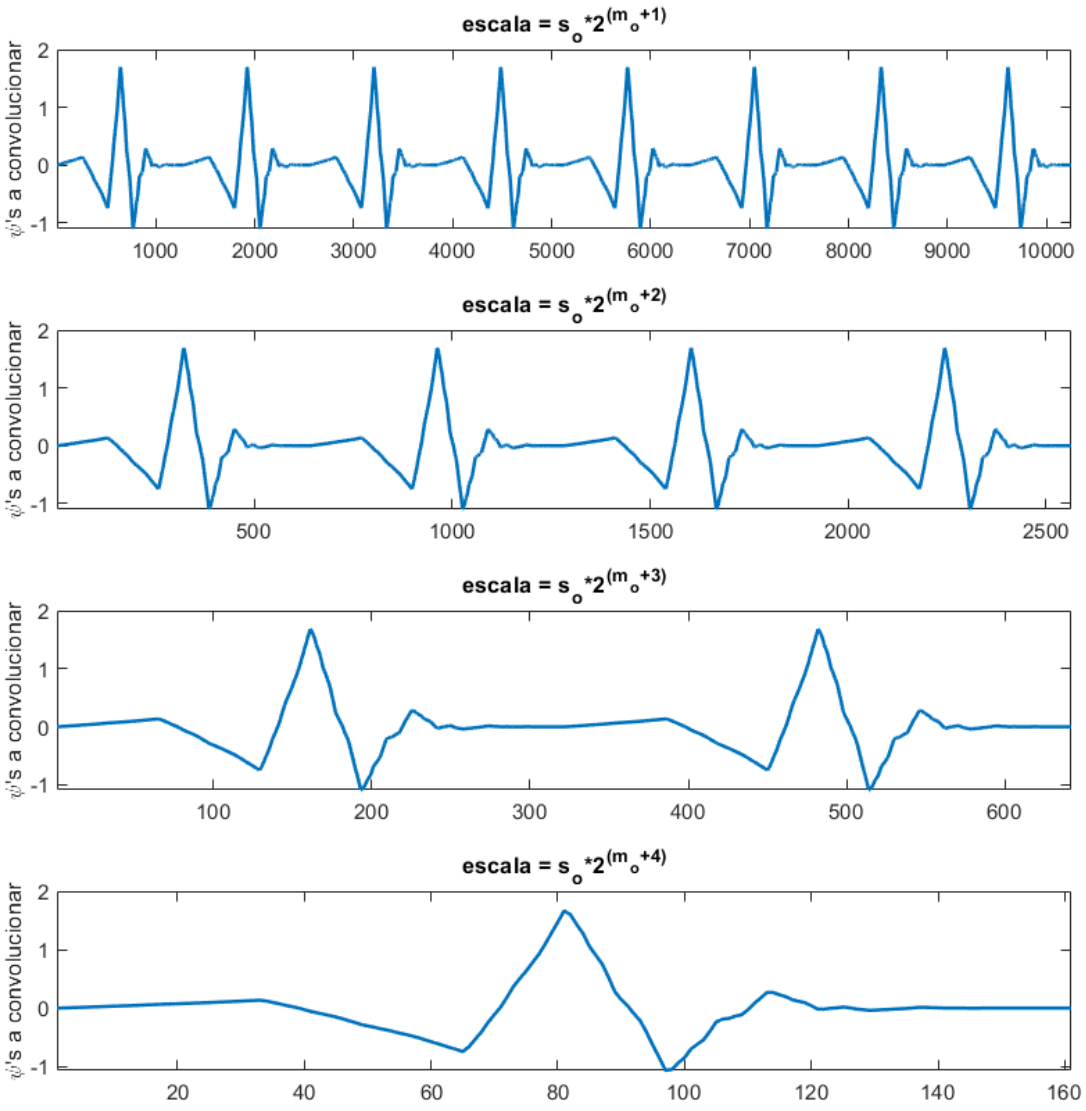
Para que sean independientes (las wavelets no se superponen en tiempo) se debe cumplir que:

$$a_m = a_0 2^m$$

$$b_{p,m} = p a_m$$

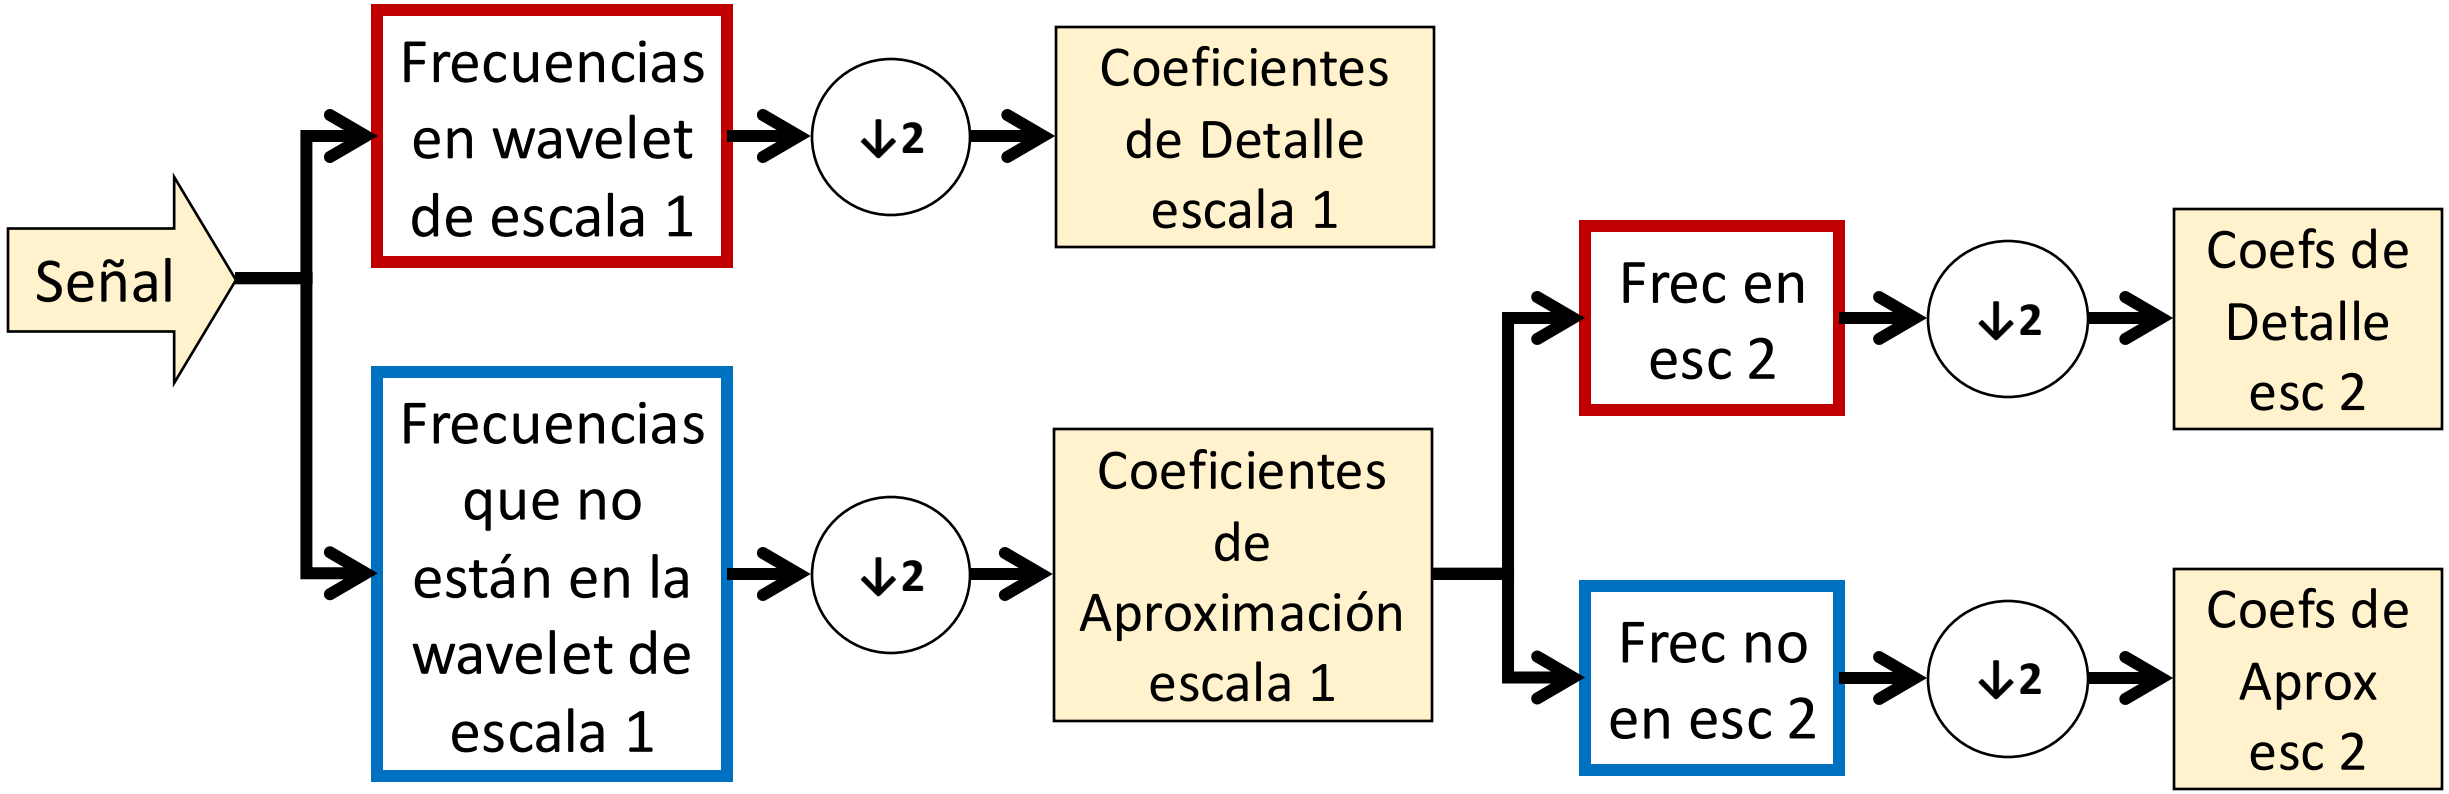
Notar que:

- A mayor escala se calculan menos b
- Existe un *m* máximo donde la wavelet ya no entra en la señal.
- No todas las wavelet madres permiten la creación de bases ortogonales.

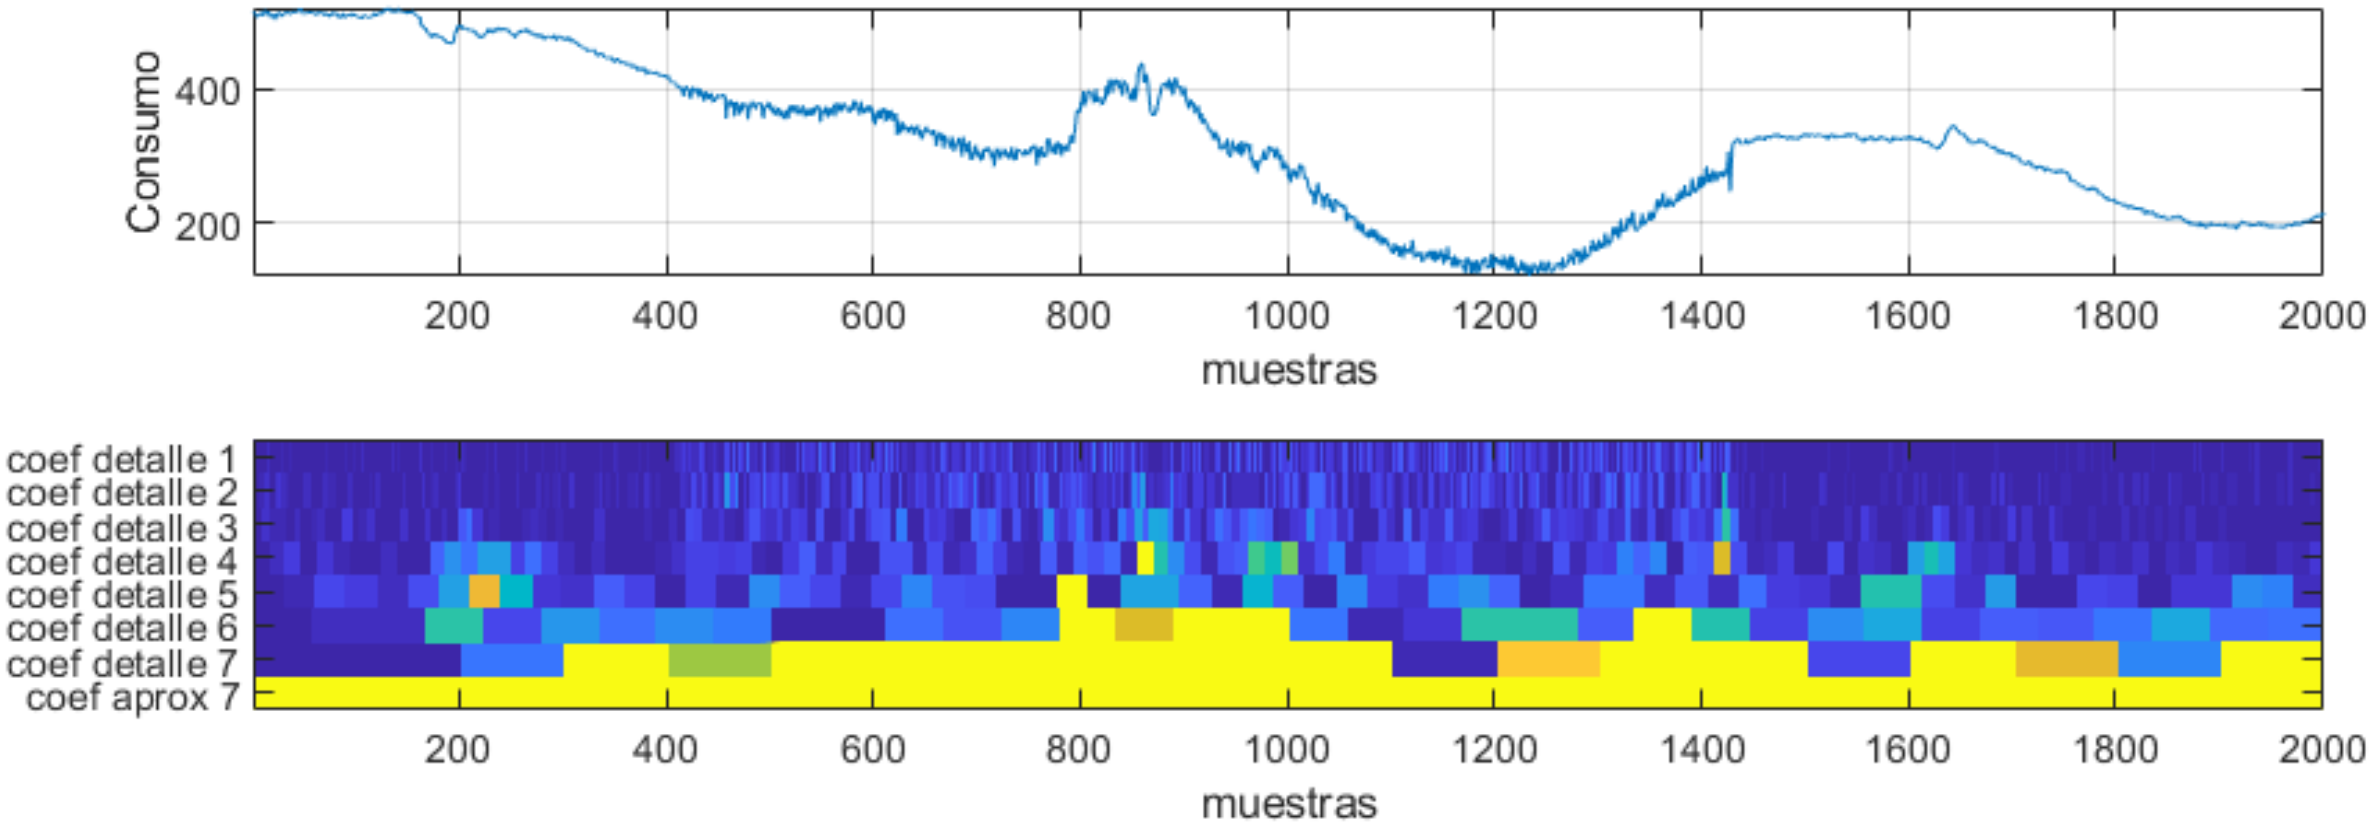


Filtros y Coeficientes

Cálculo más eficiente (mediante FFT) como un banco de **filtros**. Los filtros **pasa-altos** dan los coeficientes de cada escala (‘Detalle’). Los **pasa-bajos** calculan que “sobra” de la señal (‘Aproximación’).



Ejemplo DWT



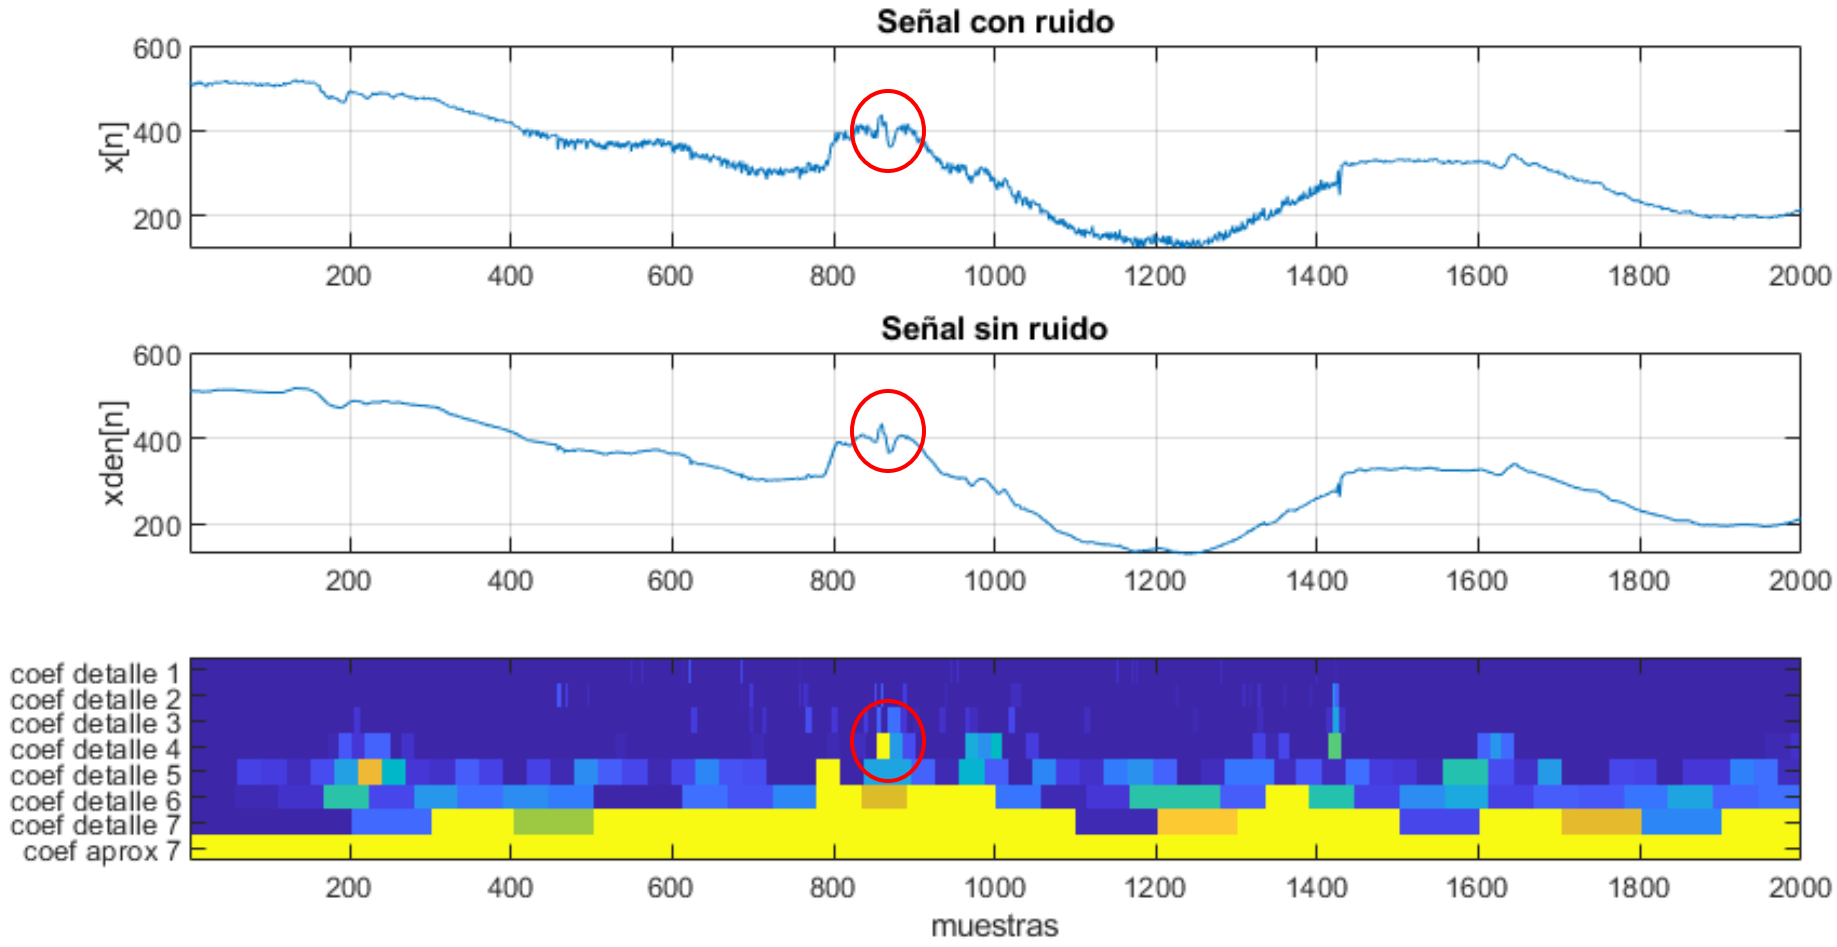
Notar la gran amplitud de los coeficientes de aproximación. La mayor parte de la energía de la señal no esta descripta por los primeros coeficientes de detalle.

Aplicación: Denoising

```
y = wdenoise(x,4,'Wavelet','db3','DenoisingMethod','UniversalThreshold')
```

En las primeras 4 escalas, se eliminan los valores por debajo de un umbral automático.

Los coeficientes no eliminados permiten cambios abruptos en la señal. No seria posible obtener este resultado mediante un filtro.

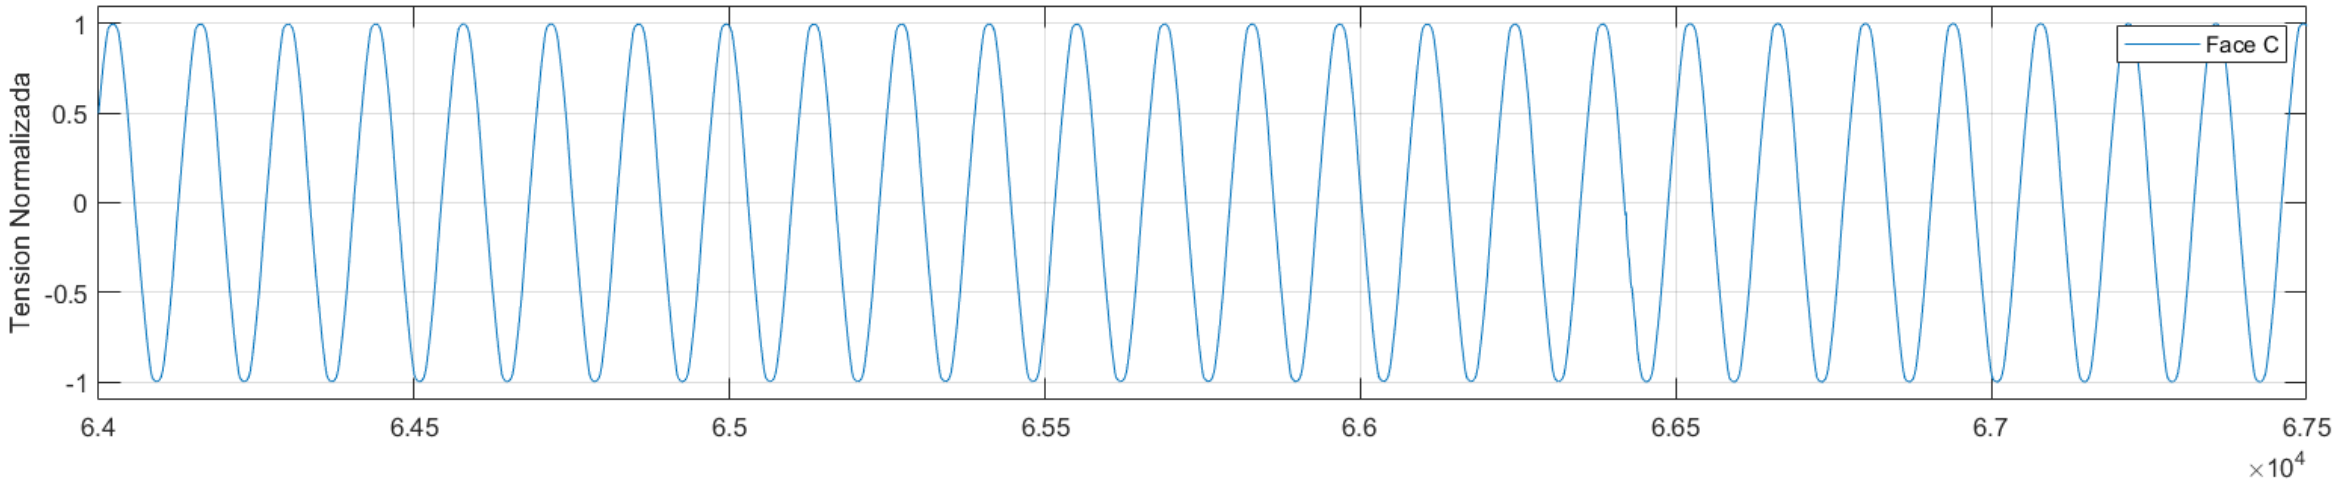


Ejemplo: Detección de Eventos en Líneas de Distribución (1)

Detección de eventos que afecten la calidad de la distribución de energía.

Un método muy utilizado es la búsqueda de picos en los primeros coeficientes de detalle, ya que poseen gran precisión temporal y describen las mayores frecuencias de la señal.

Ejemplo utilizando solo la tensión de una fase:



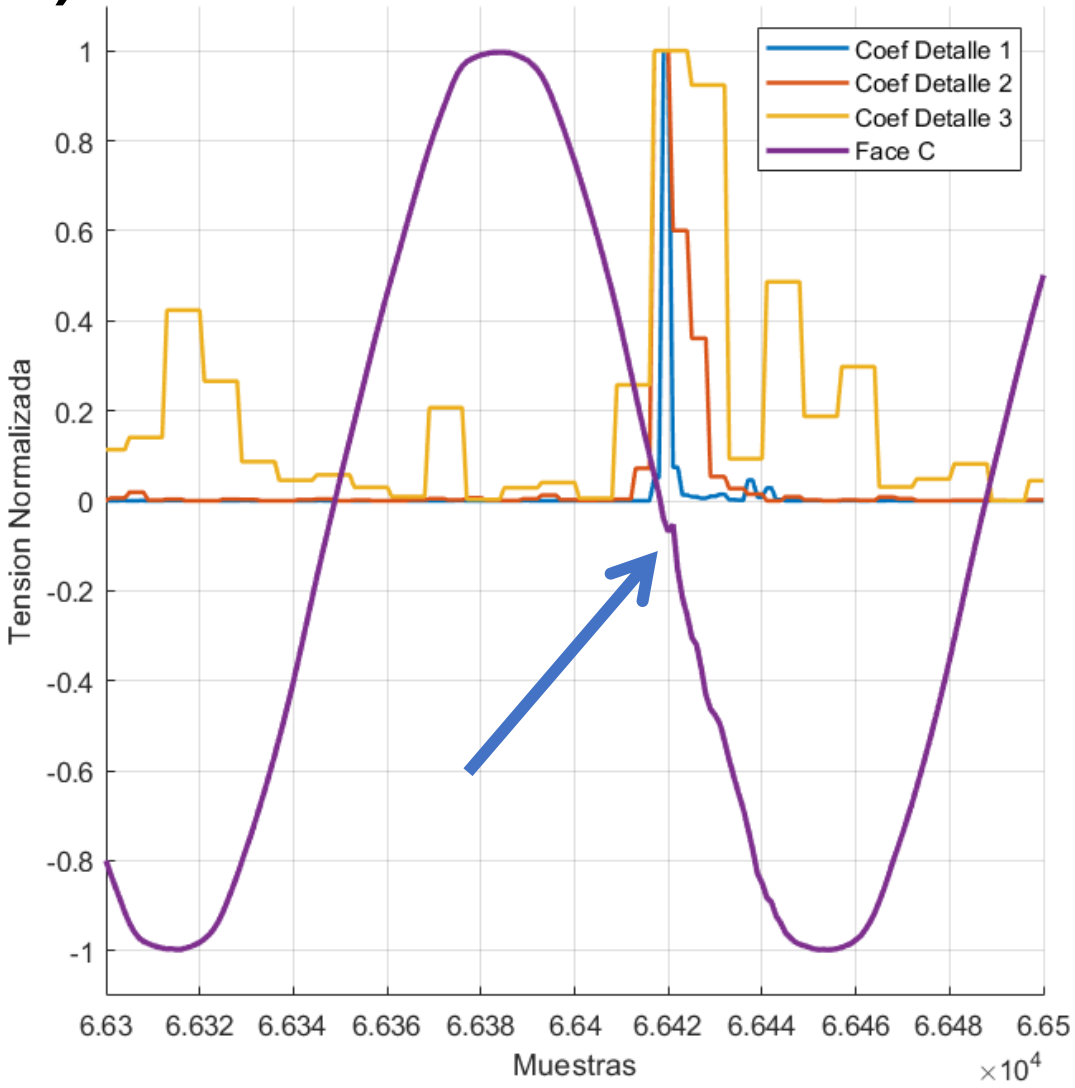
Código en *ejemplo_deteccion_fallas.m*

Ejemplo: Detección de Eventos en Líneas de Distribución (2)

Criterio de Detección:

Cada señal de detalle se eleva al cuadrado y se normaliza para que su máximo sea 1. Luego se buscan los instantes donde se presente valores que superen un umbral.

En este caso se observa la carga de un capacitor de Shunt, los propios valores obtenidos pueden ser utilizados para clasificar el evento ya que representan sus características en tiempo/frecuencia.



Otras Aplicaciones



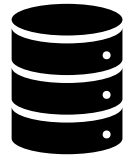
Detección de Tiempos de Interés

- En cada escala los coeficientes de mayor amplitud marcan tiempos donde la señal tiene picos en su banda de frecuencia.
- Ejemplo: localización de fallas en líneas de transmisión.



Extracción de Características

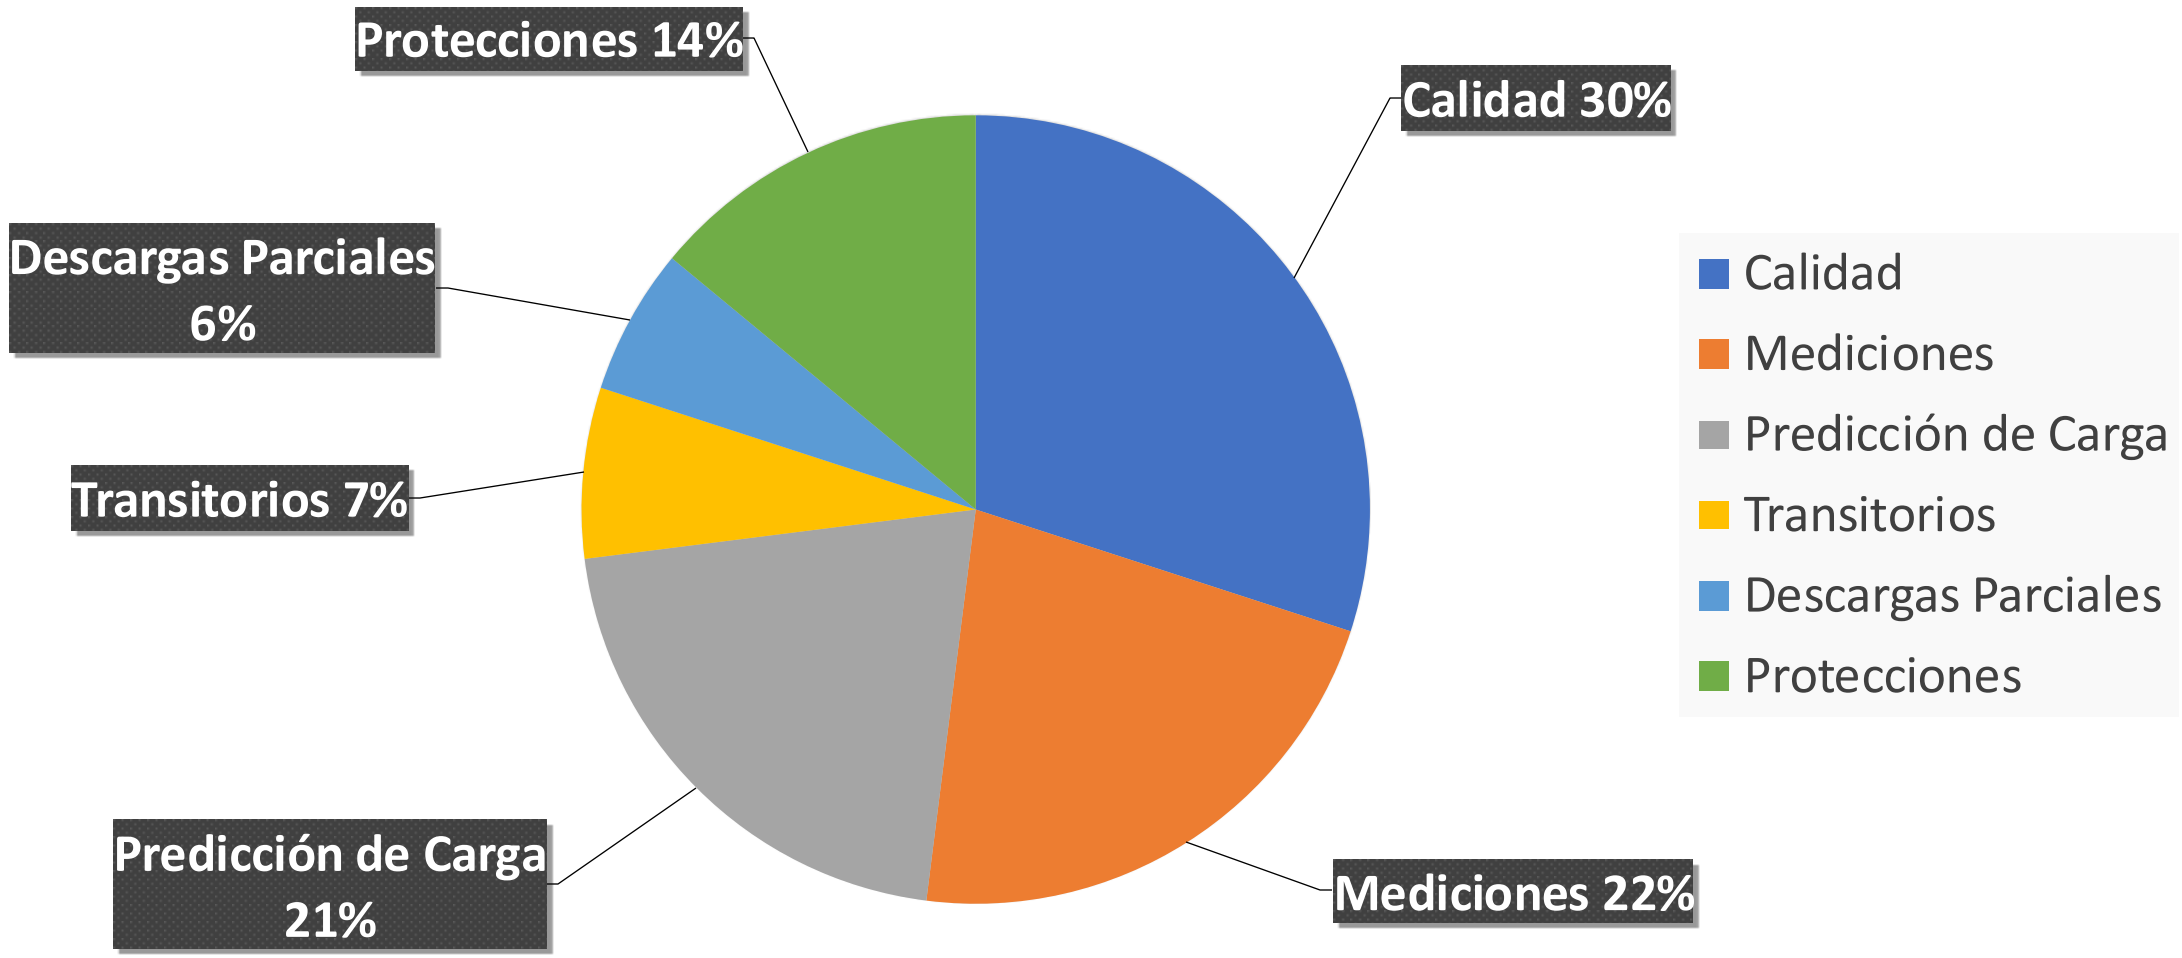
- Pocos coeficientes pueden resumir las características tiempo/frecuencia de la señal.
- Ejemplo: Clasificación de cortocircuitos en turbinas eólicas.
- Ejemplo: Caracterización de generación y cargas.
- Ejemplo: Caracterización de de calidad de potencia.



Compresión de Datos

- Consecuencia intermedia del denoising.
- La señal queda definida por una cantidad de coeficientes menor al largo de la señal.
- Utilizado para optimizar tanto la transmisión como el almacenamiento de series temporales.

Distribución temática de los trabajos que aplican wavelets en áreas relacionadas a los sistemas de potencia



Fuente: Wavelet Transform Analysis to Applications in Electric Power Systems. Mario Orlando Oliveira, et al. 2019

Matlab APPS Recomendadas



- **signalAnalyzer**

  Interfaz grafica para filtrado y visualización de espectro, periodograma, etc con ventaneo de señales discretas.

- **waveletSignalDenoiser**

  Herramienta grafica para eliminar ruido utilizando WDT.

- **waveletAnalyzer**

  Múltiples aplicaciones graficas aplicando Wavelets.

Bibliografía

- Oppenheim, a. V. (1998). Señales Y Sistemas (2a. Ed.). Mexico: prentice-hall/hispanoamericana.
- https://la.mathworks.com/help/matlab/math/basic-spectral-analysis.html
- D. L. Fugal, “Conceptual Wavelets in Digital Signal Processing,” Space & Signals Technical Publishing, 2009.
- https://www.mathworks.com/help/wavelet/examples/cwt-based-time-frequency-analysis.html
- https://www.mathworks.com/help/wavelet/ug/wavelet-denoising.html
- Wavelet Transform Analysis to Applications in Electric Power Systems. Mario Orlando Oliveira, José Horacio Reversat y Lucas Alberto Reynoso. 2019. DOI: 10.5772/intechopen.85274
- Alvaro Furlani Bastos. "Development of an algorithm for detection and classification of capacitor switching events." PhD diss., 2015

Gracias!



fchaure.carrd.co

fchaure@fi.uba.ar